TP 1.1 - SIMULACIÓN DE UNA RULETA

Brizio Augusto
Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Rosario, Argentina
brizioaugusto@gmail.com

Casermeiro Gonzalo Nicolás
Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Rosario, Argentina
gonzacasermeiro@gmail.com

Messina Tiziano Leonel
Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Rosario, Argentina
tizilmessina@gmail.com

De la Rosa Valentin
Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Rosario, Argentina
mferreyra079@gmail.com

May 11, 2026

ABSTRACT

Este trabajo presenta el desarrollo de una simulación computacional de una ruleta europea utilizando Python 3.12. El objetivo principal es modelar el comportamiento aleatorio del juego mediante la generación de números enteros entre 0 y 36, representando los posibles resultados de cada tirada. A partir de una cantidad configurable de tiradas y corridas independientes, se analizan distintas variables estadísticas como la frecuencia absoluta, la frecuencia relativa, la media y la varianza de los resultados obtenidos.

El programa permite ingresar por consola los parámetros de simulación, incluyendo la cantidad de corridas, la cantidad de tiradas por corrida y el número elegido para estudiar su aparición. Luego, se generan gráficos mediante Matplotlib que permiten comparar el comportamiento simulado con los valores teóricos esperados. Los resultados muestran cómo, al aumentar el número de tiradas, las frecuencias relativas tienden a estabilizarse cerca de la probabilidad teórica de ocurrencia de cada número, igual a $1/37$. Asimismo, la media y la varianza acumuladas tienden a aproximarse a sus valores esperados, evidenciando conceptos fundamentales de probabilidad y estadística, como la ley de los grandes números y el comportamiento de los estimadores muestrales.

La simulación constituye una herramienta práctica para estudiar fenómenos aleatorios, observar la variabilidad entre corridas independientes y vincular los resultados experimentales con el modelo probabilístico teórico de la ruleta.

1 Introducción

La ruleta es uno de los juegos de azar más emblemáticos de los casinos modernos. Su versión europea, introducida en el Casino de Montecarlo en 1842 por los hermanos Blanc, consta de 37 casilleros numerados del 0 al 36, lo que otorga a la casa un margen estadístico del $2{,}7\%$ $(1/37)$ sobre el jugador.

Desde el punto de vista probabilístico, cada tirada de la ruleta constituye una variable aleatoria discreta con distribución uniforme sobre el conjunto $\{0, 1, \ldots, 36\}$. Esto implica que el valor esperado de cada resultado es $\mu = 18$, la varianza teórica es $\sigma^2 = \frac{37^2-1}{12} \approx 114{,}33$, y la probabilidad de obtener cualquier número específico es $p = 1/37 \approx 0{,}027$.

La simulación computacional permite estudiar experimentalmente el comportamiento de sistemas estocásticos, contrastando los resultados obtenidos con las predicciones del modelo teórico. En este trabajo se desarrolla un programa en Python 3 que modela el funcionamiento del plato de una ruleta europea, generando múltiples corridas independientes de tiradas configurables por el usuario.

El objetivo principal es verificar, a través de la experimentación numérica, conceptos fundamentales de la teoría de probabilidades: la convergencia de la frecuencia relativa a la probabilidad teórica, la estabilización de la media y la

varianza muestral acumuladas hacia sus valores esperados, y la distribución de las medias finales de cada corrida en torno a μ, fenómeno descripto por el *Teorema Central del Límite*.

El presente informe se organiza de la siguiente manera: la Sección 2 describe los métodos y fórmulas empleadas; la Sección 3 presenta los resultados gráficos obtenidos junto con su interpretación en relación con la teoría; y la Sección 4 expone las conclusiones del trabajo.

2 Métodos

2.1 Modelo de la ruleta europea

Se simuló una ruleta europea con 37 casilleros numerados del 0 al 36. Cada tirada se modela como una variable aleatoria discreta X con distribución uniforme:

$$P(X = k) = \frac{1}{37}, \quad k \in \{0, 1, \ldots, 36\} \tag{1}$$

cuyos parámetros teóricos son:

$$\mu = \frac{0 + 36}{2} = 18 \tag{2}$$

$$\sigma^2 = \frac{37^2 - 1}{12} = \frac{1368}{12} \approx 114{,}33 \tag{3}$$

$$\sigma = \sqrt{\sigma^2} \approx 10{,}69 \tag{4}$$

2.2 Generación de valores aleatorios

Los valores de cada tirada se generaron mediante la función `random.randint(0, 36)` de Python 3, que produce enteros pseudoaleatorios con distribución uniforme discreta en el intervalo cerrado $[0, 36]$. El programa admite una semilla opcional (`-semilla`) para reproducir exactamente cualquier simulación.

2.3 Parámetros de la simulación

El programa recibe tres parámetros obligatorios por línea de comandos:

- **-n / –tiradas**: cantidad de tiradas de la ruleta por corrida.
- **-c / –corridas**: cantidad de corridas independientes.
- **-e / –elegido**: número a estudiar ($0 \leq e \leq 36$).

Ejemplo de invocación:

```
python simulacion_ruleta.py -c 30 -n 1000 -e 17
```

2.4 Estadísticos acumulados

Para cada corrida de n tiradas $\{x_1, x_2, \ldots, x_n\}$, se calcularon los siguientes estadísticos en forma acumulada. Esto significa que, para cada $i \in \{1, \ldots, n\}$, el estadístico se recalcula incorporando la tirada x_i, permitiendo observar su evolución a lo largo del experimento.

Frecuencia relativa acumulada del número elegido e:

$$fr_i = \frac{1}{i} \sum_{j=1}^{i} \mathbf{1}_{[x_j = e]} \tag{5}$$

donde $\mathbf{1}_{[x_j=e]}$ es la función indicadora, que vale 1 si la tirada x_j coincide con el número elegido e, y 0 en caso contrario. En otras palabras, fr_i representa la proporción de veces que apareció el número e en las primeras i tiradas. Su valor teórico esperado es $fre = 1/37 \approx 0{,}027$.

Media acumulada:

$$\bar{x}_i = \frac{1}{i} \sum_{j=1}^{i} x_j \tag{6}$$

La media acumulada representa el promedio de los valores obtenidos en las primeras i tiradas. Dado que la ruleta europea es una distribución uniforme discreta en $\{0, 1, \ldots, 36\}$, se espera que $\bar{x}_i$ converja al valor teórico $\mu = 18$ a medida que i crece.

Varianza acumulada:

$$s_i^2 = \frac{1}{i} \sum_{j=1}^{i} x_j^2 \; - \; \bar{x}_i^2 \tag{7}$$

La varianza mide la dispersión de los resultados respecto a la media. Se utiliza el estimador poblacional (divisor i), equivalente a $E[X^2] - (E[X])^2$. Su valor teórico es $\sigma^2 = (37^2 - 1)/12 \approx 114{,}33$.

Desvío estándar acumulado:

$$s_i = \sqrt{s_i^2} \tag{8}$$

El desvío estándar es la raíz cuadrada de la varianza y se expresa en las mismas unidades que los datos originales, facilitando su interpretación. Su valor teórico es $\sigma = \sqrt{114{,}33} \approx 10{,}69$.

En todos los casos, por la *Ley de los Grandes Números*, se espera que cada estadístico converja a su valor teórico a medida que $i \to \infty$, como se verifica en las gráficas de la Sección 3.

2.5 Cantidad de corridas y el Teorema Central del Límite

Se eligieron $c = 30$ corridas independientes, cada una compuesta por $n = 1000$ tiradas. Esta configuración permite observar dos fenómenos estadísticos complementarios.

Dentro de cada corrida: Ley de los Grandes Números. A medida que el número de tiradas i crece, los estadísticos acumulados convergen a sus valores teóricos. En particular, la media acumulada satisface:

$$\bar{x}_i \to \mu = 18 \quad \text{cuando } i \to \infty \tag{9}$$

Este fenómeno es descripto por la *Ley de los Grandes Números* y se observa en las gráficas individuales de cada corrida.

Entre corridas: Teorema Central del Límite. Cada corrida produce una media final $\bar{x}^{(k)}$, con $k \in \{1, \ldots, c\}$. El *Teorema Central del Límite* (TCL) establece que, para muestras de tamaño n suficientemente grande, la distribución de estas medias finales se aproxima a una distribución normal, independientemente de la distribución original de X:

$$\bar{X}_n \xrightarrow{d} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right) = \mathcal{N}\left(18, \frac{114{,}33}{1000}\right) \tag{10}$$

Con $n = 1000$ tiradas, el error estándar de la media resulta:

$$\frac{\sigma}{\sqrt{n}} = \frac{10{,}69}{\sqrt{1000}} \approx 0{,}338 \tag{11}$$

Esto implica que las medias finales de cada corrida deberían concentrarse en el intervalo aproximado $(17{,}3;\ 18{,}7)$. Este comportamiento se verifica en el histograma de medias finales (Sección 3), donde las $c = 30$ medias forman una distribución acampanada centrada en $\mu = 18$.

En síntesis, la LGN explica la convergencia de cada curva individual, mientras que el TCL explica la distribución de esas convergencias entre corridas distintas. Este trabajo ilustra ambos fenómenos de forma simultánea.

2.6 Herramientas utilizadas

La implementación se realizó íntegramente en Python 3, empleando exclusivamente bibliotecas de la distribución estándar y `Matplotlib` para la generación de gráficos. No se utilizaron bibliotecas estadísticas externas (como NumPy o SciPy), de modo que todos los estadísticos fueron calculados mediante bucles explícitos sobre listas.

3 Resultados y Discusión

Los resultados presentados a continuación fueron obtenidos ejecutando la simulación con los parámetros $c = 30$ corridas, $n = 1000$ tiradas por corrida y número elegido $e = 17$. Para cada gráfica se compara el comportamiento simulado con el valor teórico esperado (línea roja punteada).

3.1 Corrida única: evolución de los estadísticos

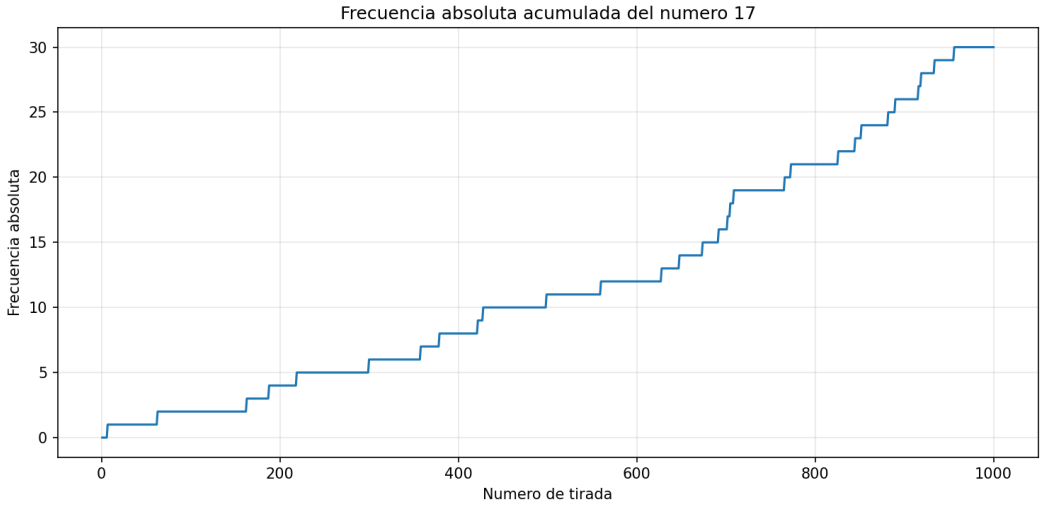


Figure 1: Frecuencia absoluta acumulada del número 17 a lo largo de 1000 tiradas.

La Figura 1 muestra el crecimiento escalonado de la frecuencia absoluta del número 17 a medida que avanza la simulación. Al finalizar las 1000 tiradas, el número apareció 30 veces, frente al valor esperado de $1000/37 \approx 27$. La diferencia de 3 apariciones es coherente con la variabilidad aleatoria propia de una muestra finita y no representa una anomalía estadística.

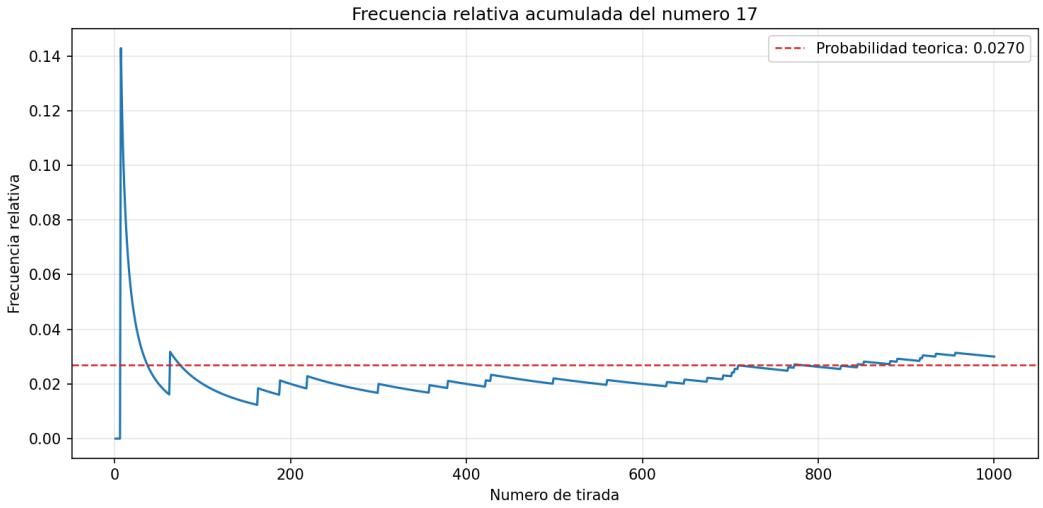


Figure 2: Frecuencia relativa acumulada del número 17 comparada con la probabilidad teórica $1/37 \approx 0{,}0270$.

La Figura 2 evidencia el comportamiento típico de la frecuencia relativa en muestras pequeñas: alta volatilidad inicial (llegando a $\approx 0{,}14$ en las primeras tiradas) seguida de una convergencia progresiva hacia la probabilidad teórica. A

partir de la tirada ≈ 400, la curva se estabiliza en torno a $1/37$, verificando experimentalmente la *Ley de los Grandes Números*: a medida que $n \to \infty$, la frecuencia relativa observada converge a la probabilidad teórica.

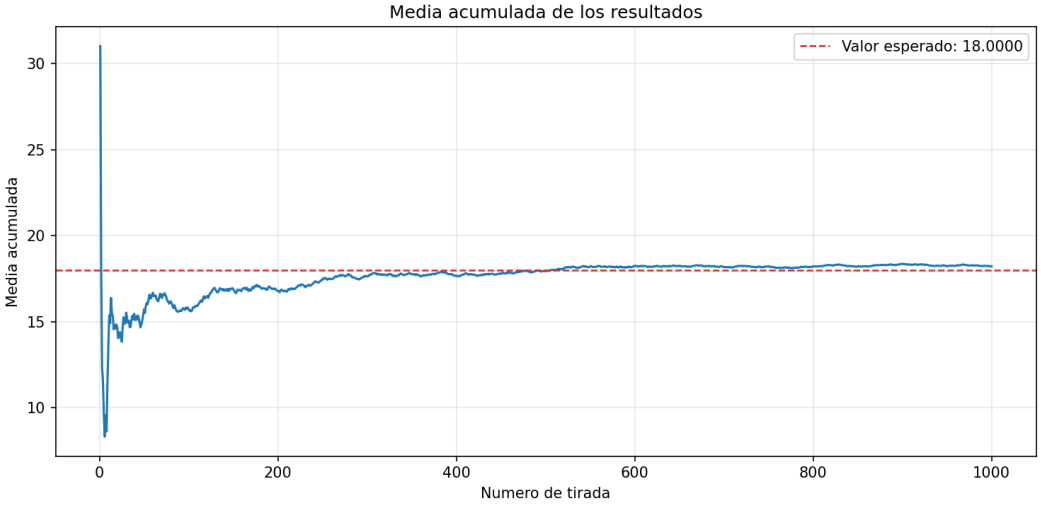


Figure 3: Media acumulada de los resultados comparada con el valor esperado $\mu = 18$.

La Figura 3 muestra que la media acumulada parte de un valor alto (≈ 31) dado que los primeros resultados fueron números grandes, y converge hacia $\mu = 18$ a partir de la tirada ≈ 400. La oscilación inicial es esperable: con pocas muestras, un valor extremo (cercano a 0 o a 36) desplaza significativamente el promedio. A medida que n crece, el peso relativo de cada tirada individual disminuye y la media se estabiliza.

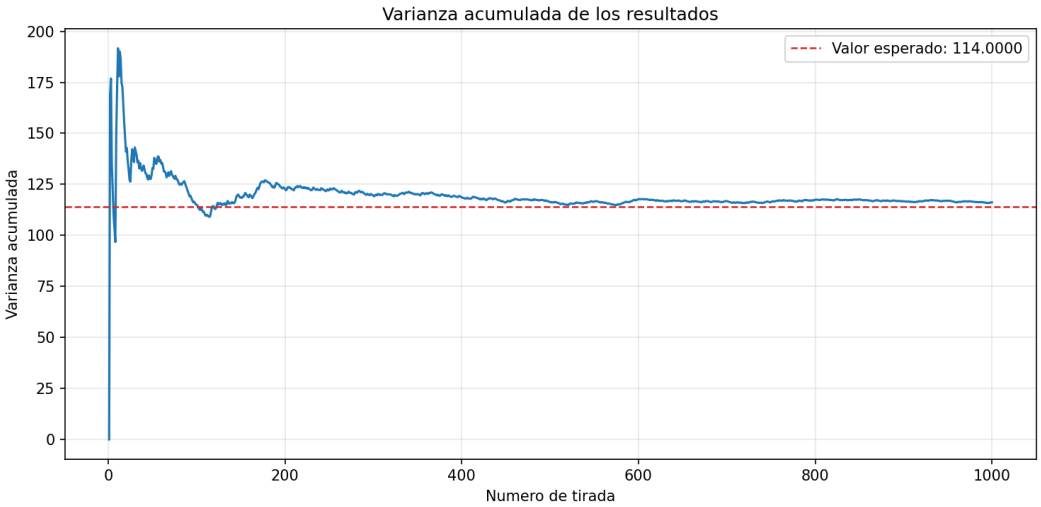


Figure 4: Varianza acumulada de los resultados comparada con el valor esperado $\sigma^2 \approx 114{,}33$.

La Figura 4 ilustra que la varianza acumulada es el estadístico que mayor inestabilidad exhibe al inicio: alcanza un pico de ≈ 190 en las primeras tiradas, para luego oscilar y converger a $\sigma^2 \approx 114$ a partir de la tirada ≈ 300. Este comportamiento se debe a que la varianza depende cuadráticamente de los valores, amplificando el efecto de los primeros resultados extremos. Al finalizar la corrida, el valor simulado es prácticamente indistinguible del teórico.

3.2 Varias corridas simultáneas

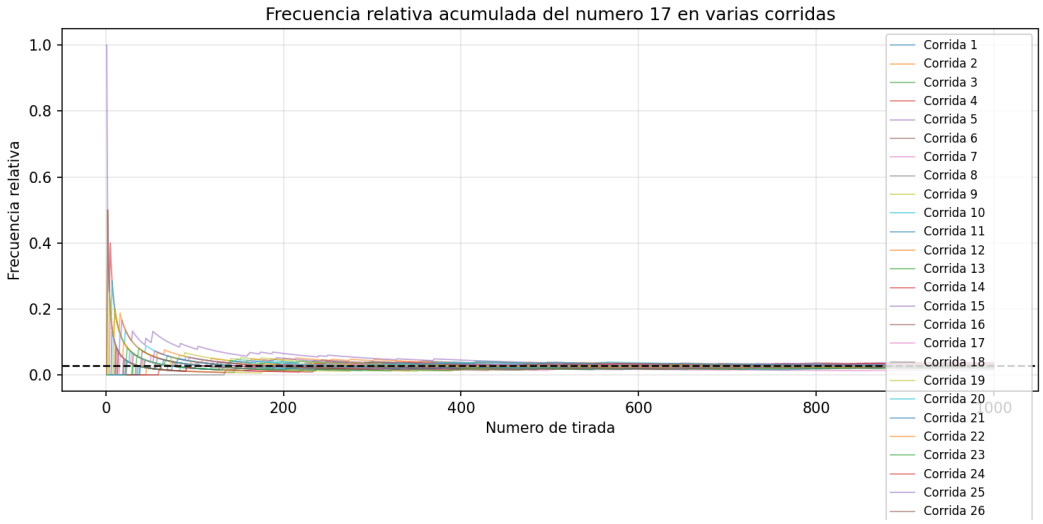


Figure 5: Frecuencia relativa acumulada del número 17 para las 30 corridas independientes.

La Figura 5 superpone las 30 corridas independientes. Se observa que todas parten con valores muy dispersos (algunas corridas arrancan en $fr = 1{,}0$ si el 17 sale en la primera tirada, otras en $fr = 0$ si no aparece durante muchas tiradas iniciales). A partir de la tirada ≈ 500, todas las curvas convergen y se agrupan en torno a $1/37$. La dispersión entre corridas disminuye a medida que n crece, lo cual es una manifestación directa de la reducción del error estándar de la estimación con el aumento del tamaño muestral.

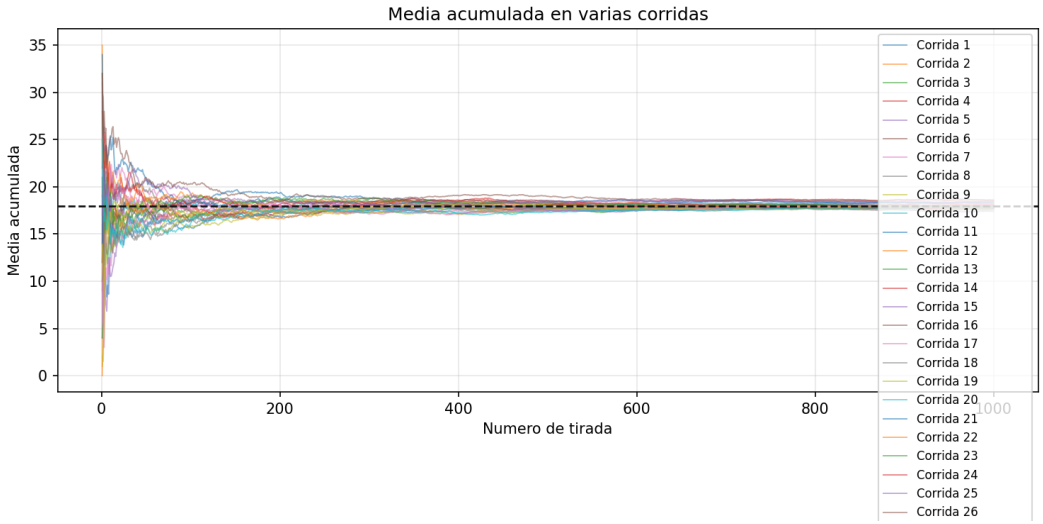


Figure 6: Media acumulada para las 30 corridas independientes comparada con $\mu = 18$.

La Figura 6 muestra que la media es el estadístico que converge más rápidamente: a partir de la tirada ≈ 200, las 30 corridas ya se encuentran muy agrupadas en torno a $\mu = 18$. La alta densidad de curvas sobre la línea teórica para $n > 400$ confirma que con muestras de ese tamaño, la estimación de la media es robusta e independiente de la corrida considerada.

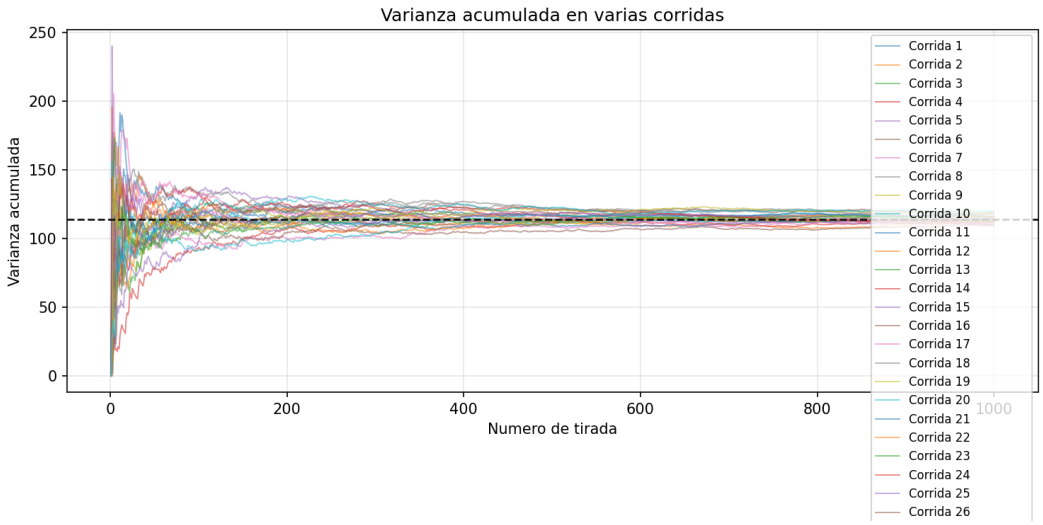


Figure 7: Varianza acumulada para las 30 corridas independientes comparada con $\sigma^2 \approx 114{,}33$.

La Figura 7 confirma que la varianza es el estadístico de convergencia más lenta. Los valores iniciales alcanzan picos de hasta ≈ 240 en algunas corridas, y la dispersión entre corridas se mantiene apreciable hasta la tirada ≈ 300. A partir de allí, todas convergen a $\sigma^2 \approx 114$, con variaciones menores al 5% del valor teórico para $n > 600$.

3.3 Distribución global y verificación del TCL

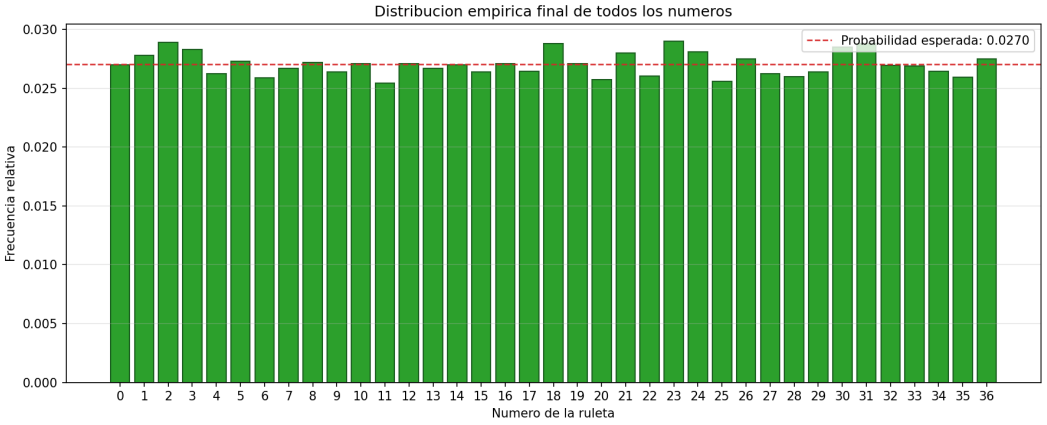


Figure 8: Distribución empírica final de los 37 números de la ruleta sobre el total de 30.000 tiradas (30×1000).

La Figura 8 muestra la frecuencia relativa final de cada número sobre el total de $30 \times 1000 = 30.000$ tiradas. Todos los valores se encuentran en el intervalo $(0{,}025;\ 0{,}029)$, muy próximos a la probabilidad esperada de $1/37 \approx 0{,}0270$. La distribución empírica es prácticamente uniforme, confirmando que el generador pseudoaleatorio de Python produce resultados acordes con el modelo teórico de distribución uniforme discreta.

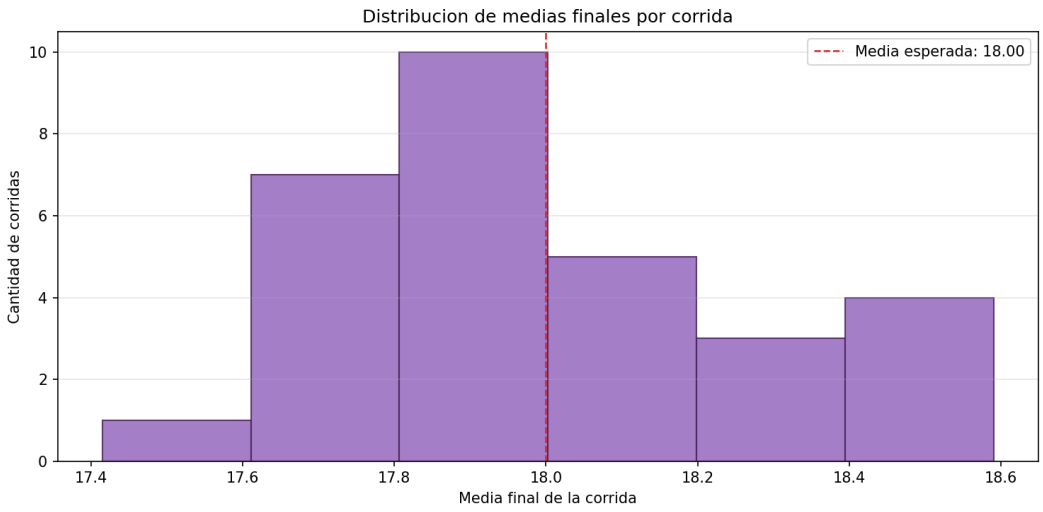


Figure 9: Histograma de las medias finales de las 30 corridas. La línea roja indica la media teórica $\mu = 18$.

La Figura 9 constituye la verificación experimental del *Teorema Central del Límite*. Las medias finales de las 30 corridas se concentran en el intervalo $(17{,}4;\ 18{,}6)$, consistente con el rango predicho por el TCL: $\mu \pm 2\,\frac{\sigma}{\sqrt{n}} = 18 \pm 0{,}676$. El histograma exhibe una forma aproximadamente acampanada centrada en $\mu = 18$, con una ligera asimetría hacia la izquierda esperable con solo 30 muestras. Con un mayor número de corridas, la distribución convergiría a una normal $\mathcal{N}(18,\ 0{,}114)$ de manera más notoria.

4 Conclusiones

El presente trabajo permitió verificar experimentalmente, mediante la simulación computacional de una ruleta europea, los principales conceptos teóricos de la probabilidad y la estadística estudiados en la materia.

En primer lugar, se comprobó la *Ley de los Grandes Números*: a medida que el número de tiradas n crece, la frecuencia relativa del número elegido, la media acumulada y la varianza acumulada convergen a sus respectivos valores teóricos ($1/37$, $\mu = 18$ y $\sigma^2 \approx 114{,}33$). Esta convergencia es progresiva y no lineal: los tres estadísticos exhiben alta volatilidad en las primeras tiradas y se estabilizan de forma sostenida a partir de $n \approx 400$.

En segundo lugar, se observó que la velocidad de convergencia difiere entre estadísticos. La media acumulada es la que converge más rápidamente (a partir de $n \approx 200$), seguida por la frecuencia relativa ($n \approx 400$) y finalmente la varianza, que es el estadístico más sensible a los valores extremos iniciales y requiere al menos $n \approx 300$ tiradas para estabilizarse. Este comportamiento es consistente con el hecho de que la varianza depende cuadráticamente de los datos, amplificando el efecto de las primeras muestras.

En tercer lugar, el histograma de medias finales de las 30 corridas confirmó el *Teorema Central del Límite*: las medias se distribuyeron en torno a $\mu = 18$ dentro del intervalo predicho teóricamente, mostrando una forma aproximadamente normal. La ligera asimetría observada es esperable con $c = 30$ corridas y desaparecería al aumentar el número de corridas.

Finalmente, la distribución empírica global de los 37 números de la ruleta resultó prácticamente uniforme, con frecuencias relativas en el intervalo $(0{,}025;\ 0{,}029)$, validando que el generador pseudoaleatorio de Python constituye una herramienta adecuada para modelar este tipo de fenómenos aleatorios.

En conclusión, la simulación demostró ser una herramienta eficaz para estudiar el comportamiento de sistemas estocásticos, permitiendo visualizar de forma intuitiva fenómenos que el modelo teórico predice pero que resultan abstractos sin una verificación experimental.

References

[1] Wikipedia, *Ruleta*, https://es.wikipedia.org/wiki/Ruleta, 2024.

[2] Wikipedia, *Ley de los grandes números*, https://es.wikipedia.org/wiki/Ley_de_los_grandes_n%C3%BAmeros, 2024.

[3] Wikipedia, *Teorema central del límite*, https://es.wikipedia.org/wiki/Teorema_central_del_l%C3%ADmite, 2024.

[4] S. Ross, *A First Course in Probability*, 8th ed. Pearson Prentice Hall, 2010.

[5] Python Software Foundation, *random — Generate pseudo-random numbers*, https://docs.python.org/3/library/random.html, 2024.

[6] J. D. Hunter, "Matplotlib: A 2D graphics environment," *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90–95, 2007.