

UNIVERSIDAD TECNOLÓGICA NACIONAL

FACULTAD REGIONAL ROSARIO

SIMULACIÓN

Autor: Pagliaro, Luis

Contenido

1. La simulación	3
1.1. Sistemas, modelos y simulación	3
2. Simulación de eventos discretos	4
2.1. Mecanismos de avance en el tiempo	4
2.2. Componentes y organización de un modelo de simulación de eventos discretos	4
2.3. Diagrama de flujo del mecanismo de avance al próximo evento	5
3. Simulación de un sistema de espera de un solo servidor	5
3.1 Medidas de desempeño	5
3.2 Diagramas de flujo para las rutinas de arribo y partida	6
4. Simulación de un sistema de inventario.....	7
4.1. Componentes	7
4.2. Diagramas de flujo para las rutinas	8
5. Etapas de un estudio de simulación	8
6. Modelos de colas	9
6.1. Características de un sistema de colas	9
6.2. Clasificación de los modelos de colas.....	10
6.3. Medidas de rendimiento para evaluar un sistema de colas.....	10
6.3.1. Medidas de rendimiento	10
6.3.2. Relaciones entre medidas de rendimiento	11
7. Análisis de los datos de salida de un único sistema	12
7.1. Comportamiento del estado transiente y estacionario de un proceso estocástico	12
7.2. Tipos de simulación respecto al análisis de los datos de salida	12
7.3. Análisis estadístico para simulaciones terminales	12
7.3.1. Estimación de la media.....	12
7.3.2. Eligiendo condiciones iniciales	14
8. Medidas múltiples de rendimiento	14
9. Comparando configuraciones de sistemas alternativos	14
9.1. Intervalos de confianza para la diferencia entre las medidas de rendimiento de dos sistemas	14
9.1.1. Intervalo de confianza t-apareado	14
9.1.2. Intervalo de confianza de Welch	15
9.2. Intervalos de confianza para comparar más de dos sistemas.....	15
9.2.1. Método de ranking y selección	15
10. Método de media de lotes	16
11. Números aleatorios comunes.....	16

1. La simulación

Llamamos sistema a un proceso de interés, y para estudiarlo científicamente tenemos que hacer suposiciones de cómo funciona.

Estas suposiciones que usualmente toman forma de relaciones lógicas o matemáticas, constituyen un modelo que se usa para tratar de obtener un entendimiento de cómo el sistema se comporta.

Si las relaciones que componen éste modelo son simples, podría ser posible usar métodos matemáticos para obtener la información exacta de las preguntas de interés; a esto se le llama una solución analítica. Sin embargo, la mayoría de los sistemas del mundo real son demasiados complejos para ser evaluados analíticamente, por lo que deben ser estudiados por simulación

1.1. Sistemas, modelos y simulación

Un sistema se define como una colección de entidades, como gente o máquinas, que actúan e interactúan juntos para lograr un objetivo lógico. En la práctica, lo que se refiere a “sistemas” depende de los objetivos de un estudio en particular.

Definimos el estado de un sistema como una colección de variables necesarias para describir un sistema en un momento en particular, relativo a los objetivos del estudio.

Categorizaremos a los sistemas en dos tipos: discretos y continuos. Un sistema discreto es aquel para el cual las variables de estado cambian instantáneamente en puntos de tiempo separados. Un sistema continuo es aquel para el cual las variables de estado cambian continuamente respecto al tiempo.

En algún punto en la vida de la mayoría de los sistemas, hay una necesidad de estudiarlos para lograr una comprensión en las relaciones entre varios componentes:

- Experimentar con el sistema real vs. Experimentar con un modelo del sistema:
Si es posible (y rentable), alterar el sistema físicamente y luego dejarlo operar bajo las nuevas condiciones. Sin embargo, raramente se hace esto, porque tal experimento costaría demasiado o perjudicaría al sistema.
Usualmente es necesario construir un modelo como representación del sistema y estudiarlo como reemplazo del sistema real. Cuando usamos un modelo, siempre está la pregunta de si refleja con precisión al sistema para los propósitos de las decisiones a ser tomadas.
- Modelo físico vs. Modelo matemático:
Los modelos físicos no son del típico tipo de modelos que son de interés en búsqueda de operaciones y análisis de sistemas.
Los modelos matemáticos representan a un sistema en términos de relaciones lógicas y cuantitativas que luego son manipuladas y cambiadas para ver cómo el modelo reacciona, y por consiguiente, cómo reaccionaría si el modelo matemático es válido.
- Soluciones analíticas vs. Simulación:
Una vez que construimos el modelo matemático, luego debe ser examinado para ver cómo puede ser usado para responder las preguntas de interés sobre el sistema que se supone representa. Si el modelo es simple, podría ser posible trabajar con sus relaciones y cantidades para obtener una solución exacta, analítica.
Sin embargo, muchos sistemas son altamente complejos, por lo que modelos matemáticos válidos de ellos son también complejos, descartando toda posibilidad de una solución analítica. En éste caso, el modelo debe ser estudiado por medio de la simulación, trabajando numéricamente el modelo para las entradas en cuestión para ver cómo afectan las medidas de desempeño de salida.

Dado que tenemos un modelo matemático a ser estudiado por medio de simulación, debemos buscar herramientas particulares para hacer esto. Es útil para éste propósito clasificar los modelos de simulación por tres diferentes dimensiones:

- Simulación de modelos estática vs. dinámica:

Una simulación estática de un modelo es una representación de un sistema en un momento particular, o uno que puede ser usado para representar un sistema en el cual el tiempo no juega ningún papel. Una simulación dinámica de un modelo representa un sistema mientras evoluciona en el tiempo.

- Simulación de modelos determinística vs. estocástica:

Si un modelo de simulación no posee componentes probabilísticos, se llama determinístico. Si un modelo de simulación tiene componentes de entrada aleatorios se llama estocástico.

- Simulación de modelos discretos vs. continuos:

Se define análogamente a sistemas discretos y continuos.

2. Simulación de eventos discretos

La simulación de eventos discretos concierne el modelado de un sistema mientras evoluciona en el tiempo por una representación en el cual las variables de estado cambian instantáneamente en puntos de tiempo separados. Estos puntos en el tiempo son en los cuales los eventos ocurren; donde un evento se define como una ocurrencia instantánea que podría cambiar el estado del sistema.

2.1. Mecanismos de avance en el tiempo

Debido a la naturaleza de los modelos de simulación de eventos discretos, debemos hacer un seguimiento del valor actual del tiempo simulado mientras la simulación procede, también necesitamos un mecanismo para avanzar el tiempo simulado de un valor a otro. Llamamos a la variable que da el valor actual del tiempo simulado, reloj de simulación.

Se han sugerido dos métodos para avanzar el reloj de simulación: avance al próximo evento y avance de tiempo a incremento fijo.


Con el avance de tiempo al próximo evento, el reloj de simulación es inicializado en cero y los tiempos de ocurrencia de eventos futuro son determinados. El reloj de simulación avanza al tiempo de ocurrencia del evento futuro más inminente, a tal punto, el estado del sistema se actualiza por el hecho de que tal evento ha ocurrido, y nuestro conocimiento de los tiempos de ocurrencia de eventos futuros es actualizado. Luego, el reloj de simulación avanza al tiempo de evento más inminente, el estado del sistema es actualizado y tiempo de eventos futuros son determinado.

2.2. Componentes y organización de un modelo de simulación de eventos discretos

- Estado del sistema: es la colección de variables de estado necesarias para describir al sistema en un tiempo particular.
- Reloj de simulación: variable que da el valor actual del tiempo simulado.
- Lista de eventos: lista que contiene el próximo tiempo en que cada tipo de evento ocurrirá.
- Contadores estadísticos: variables utilizadas para almacenar información estadística sobre el desempeño del sistema.
- Rutina de inicialización: es un subprograma que inicializa el modelo de simulación al tiempo cero.
- Rutina de tiempo: subprograma que determina el próximo evento de la lista de eventos y luego actualiza el reloj de simulación al tiempo donde este evento ocurrirá.

- Rutina de eventos: subprograma que actualiza el estado del sistema cuando un tipo de evento particular ocurre.
- Rutina de librería: conjunto de subprogramas utilizados para generar observaciones aleatorias de distribuciones de probabilidad que fueron determinadas como parte del modelo de simulación.
- Generador de reportes: es un subprograma que computa estimadores de las medidas de desempeño deseadas y produce un reporte cuando la simulación termina.
- Programa principal: es un subprograma que invoca la rutina de tiempo para determinar el próximo evento y luego transfiere el control a la rutina de evento correspondiente para actualizar apropiadamente el estado del sistema. El programa principal podría también comprobar la terminación e invocar al generador de reportes cuando la simulación finalice.

2.3. Diagrama de flujo del mecanismo de avance al próximo evento



3. Simulación de un sistema de espera de un solo servidor

3.1 Medidas de desempeño

Para medir el desempeño del sistema, observaremos estimadores de tres cantidades. Primero, estimaremos la demora promedio en cola esperada de los n clientes que completaron sus demoras durante la simulación. Denotamos esta cantidad como $d(n)$. De una corrida de simulación, resultan las demoras $D_1, D_2, \dots, D_n$, por lo tanto, el estimador es:

$$\hat{d}(n) = \frac{\sum_{i=1}^n D_i}{n}$$

Otra medida de rendimiento es el número promedio de clientes en cola esperado, denotada $q(n)$. Para definir esta medida utilizaremos los valores $Q(t)$, el número de clientes en cola en el tiempo t y $T(n)$, el tiempo requerido para observar las n demoras en cola. Entonces:

$$\hat{q}(n) = \frac{\int_0^{T(n)} Q(t) dt}{T(n)}$$


La tercera medida de desempeño es una medida de cuan ocupado está el servidor. La utilización del servidor es la proporción esperada de tiempo durante la simulación que el servidor está ocupado, denotado $u(n)$. Definimos la función “ocupado”:

$$B(t) = \begin{cases} 1 & \text{si el servidor está ocupado en el tiempo } t \\ 0 & \text{si el servidor está desocupado en el tiempo } t \end{cases}$$

Entonces:

$$\hat{u}(n) = \frac{\int_0^{T(n)} B(t) dt}{T(n)}$$

3.2 Diagramas de flujo para las rutinas de arribo y partida




4. Simulación de un sistema de inventario

4.1. Componentes

- Tiempos entre demandas.
- Tamaño de las demandas (D).
- Costo del pedido: $k + (i * Z)$, donde k es el costo base, i es el costo incremental por ítem y Z la cantidad pedida.
- Retardo de envío: tiempo requerido para que llegue un pedido.
- Política estacionaria (s, S): $Z = \begin{cases} S - I & \text{si } I < s \\ 0 & \text{si } I \geq s \end{cases}$, donde I es el nivel de inventario al momento de la evaluación de inventario.
- Nivel de inventario a tiempo t , denotado $I(t)$.
- Número de ítems en posesión en el inventario a tiempo t : $I^+(t) = \max\{I(t), 0\}$.
- Número de ítems faltantes en el inventario a tiempo t : $I^-(t) = \max\{-I(t), 0\}$.
- Costo de mantenimiento de ítems por unidad de tiempo, denotado h .
- Número de ítems en el inventario para el n -ésimo período de tiempo: $\bar{I}^+ = \frac{\int_0^n I^+(t) dt}{n}$.
- Promedio de costo de mantenimiento por unidad de tiempo: $h * \bar{I}^+$.
- Costo de faltante de ítems por unidad de tiempo, denotado π .
- Número de ítems faltantes en el inventario para el n -ésimo período de tiempo: $\bar{I}^- = \frac{\int_0^n I^-(t) dt}{n}$.
- Promedio de costo de faltante por unidad de tiempo: $\pi * \bar{I}^-$.

4.2. Diagramas de flujo para las rutinas



5. Etapas de un estudio de simulación

1. Formular el problema y planificar el estudio:

Cada estudio debe comenzar con una declaración de los objetivos. Los diseños alternativos del sistema a ser estudiado deben ser delineados, y los criterios para evaluar la eficacia de estas alternativas deben ser dados. El estudio debe ser planteado en términos del número de personas, el costo y el tiempo requerido para cada aspecto del estudio.

2. Recolectar datos y definir el modelo:

Información y datos deben ser recolectados del sistema de interés y deben ser usados para especificar procedimientos para operar y distribuciones de probabilidad para las variables aleatorias usadas en el modelo.

3. ¿Es válido el modelo?

Es imperativo para el modelador involucrar personas en el estudio relacionadas con el uso actual del sistema. También debería haber interacción con la persona que toma las decisiones. En adición, la adecuación de las distribuciones de probabilidad especificadas para generar variables de entrada aleatorias debería ser comprobada usando la prueba de bondad de ajuste.

4. Construir un programa de computadora y verificar:

Se debe decidir si usar un lenguaje de programación de propósitos generales o uno diseñado para simulaciones.

5. Hacer corridas piloto:

Se hacen corridas piloto del modelo verificado por propósito de validación.

6. ¿Es válido el modelo?

Las corridas piloto pueden ser usadas para probar la sensibilidad de la salida del modelo ante pequeños cambios en un parámetro de entrada. Si la salida cambia significativamente, un mejor estimador para el parámetro de entrada debe ser obtenido.

7. Diseño de experimentos:

Para cada diseño del sistema a ser simulado, se tienen que tomar decisiones en temas como las condiciones iniciales de las corridas de la simulación, la longitud del período de calentamiento, la longitud de las corridas de la simulación y el número de corridas independientes de la simulación para cada alternativa.

8. Realizar corridas de producción:

Las corridas de producción se hacen para proveer datos sobre el desempeño de los diseños del sistema.

9. Analizar los datos de salida:

Se utiliza un intervalo de confianza para una medida de desempeño para un diseño en particular del sistema o para decidir qué sistema simulado es mejor relativo a alguna medida de desempeño especificada.

10. Documentar, presentar e implementar resultados:

Es importante documentar las cosas que se asumieron en el modelo, así como el programa.

6. Modelos de colas

6.1. Características de un sistema de colas

- Población de clientes: conjunto de todos los posibles clientes de un sistema de colas. Para problemas en donde el número de clientes potenciales es bastante grande (cientos o miles), el tamaño de la población se considera como si fuera infinito.
- Proceso de llegada: es la forma en que los clientes llegan a solicitar un servicio. La característica principal del proceso de llegada es el tiempo entre llegadas, que es el intervalo de tiempo que existe entre dos llegadas sucesivas. Mientras menor sea el intervalo de tiempo, con más frecuencia llegarán los clientes, lo cual aumenta la demanda de servidores disponibles. Existen dos clases de tiempos entre llegadas: determinísticos, en el que los clientes sucesivos llegan en un mismo intervalo de tiempo, fijo y conocido; y probabilístico, en el que el tiempo entre llegadas sucesivas es incierto y variable. Se describe mediante una distribución de probabilidad.
- Proceso de colas: es la forma en que los clientes esperan para ser atendidos. Si los clientes esperan en una sola línea para tener acceso al siguiente prestador de servicio disponible en el sistema, el sistema se llama de colas de una sola línea. Si los clientes pueden elegir entre varias filas en la que deben esperar a ser atendidos, el sistema es de colas de líneas múltiples.

Otra característica del proceso de colas es el número de espacios de espera en cada fila, es decir, el número de clientes que pueden esperar (o que esperarán) para ser atendidos en cada línea. Este número puede ser finito o infinito.

Otra característica del proceso de colas es la disciplina de colas, es decir, la forma en que los clientes que esperan son seleccionados para ser atendidos. Estas pueden ser: FIFO, LIFO o selección por prioridad.

- El proceso de servicio: es la forma en que los clientes son atendidos. Puede existir más de una estación en el sistema en la cual se proporcione el servicio requerido. Los sistemas pueden ser de colas de canal múltiple, en los cuales los clientes que llegan pueden pasar a una de varias estaciones de trabajo posibles; y sistemas de colas de canal sencillo, en los cuales los clientes que llegan pasan por una sola estación de trabajo.

En los sistemas de canal múltiple, los servidores pueden ser idénticos, en el sentido de que proporcionan el mismo servicio, o no idénticos. En los sistemas de canal sencillo pueden existir muchos servidores, que juntos, llevan a cabo la tarea necesaria.

Otra característica del proceso de servicio es el número de clientes atendidos al mismo tiempo en una estación.

Otra característica más de un proceso de servicio es si se permite o no la prioridad, esto es si un servidor puede detener el proceso con el cliente que está atendiendo para dar lugar a un cliente que acaba de llegar.

Cualquiera que sea el proceso de servicio, es necesario tener una idea de cuánto tiempo se requiere para llevar a cabo el servicio. Esta cantidad es importante debido a que cuanto más dure el servicio, más tendrán que esperar los clientes que llegan. Este tiempo se denomina tiempo de servicio, y puede ser determinístico, en el que cada cliente requiere la misma cantidad conocida de tiempo para ser atendido; y probabilístico, en el que cada cliente requiere una cantidad distinta e incierta de tiempo de servicio.

6.2. Clasificación de los modelos de colas

La notación utilizada para describir los modelos de colas es la notación Kendall. En ella se describe el proceso de llegada, el proceso de servicio, el proceso de colas, la cantidad de clientes en el sistema y la cantidad de clientes de la población.

- Proceso de llegada: estos símbolos describen la distribución de tiempos entre llegadas:
 - D: tiempos entre llegadas determinísticos.
 - M: tiempos entre llegadas probabilísticos con distribución exponencial.
 - G: tiempos entre llegadas probabilísticos con distribución general.
- Proceso de servicio: estos símbolos describen la distribución de tiempos de servicio:
 - D: tiempos de servicio determinísticos.
 - M: tiempos de servicio probabilísticos con distribución exponencial.
 - G: tiempos de servicio probabilísticos con distribución general.
- Proceso de colas: este número, c , representa cuantas estaciones paralelas existen en el sistema.
- Un número K , que representa el número máximo de clientes que pueden estar en el sistema en cualquier momento.
- Un número L , que representa el número total de clientes de la población.

Cuando se omite alguno de los símbolos, se considera que el número es infinito.

6.3. Medidas de rendimiento para evaluar un sistema de colas

Cualquier sistema de colas pasa por dos fases lógicas. La fase transitoria, que es el período inicial de un sistema de colas en que se conservan los efectos de las condiciones iniciales, y la fase de estado estable, que es la condición del sistema después de que se han eliminado las condiciones iniciales.

Todos los modelos analíticos son válidos siempre que el sistema haya llegado al estado estable.

6.3.1. Medidas de rendimiento

Las medidas de rendimiento son un valor numérico que se utiliza para evaluar los méritos de un sistema de colas en estado estable.

- Tiempo promedio de espera en cola (W_q): tiempo promedio que un cliente que llega tiene que esperar en la cola antes de ser atendido.
- Tiempo promedio en el sistema (W): tiempo promedio que un cliente invierte desde su llegada hasta su salida en un sistema de colas.
- Longitud media de la cola (L_q): número promedio de clientes que se encuentran en la fila esperando a ser atendidos.

- Número medio de clientes en el sistema (L): número promedio de clientes que se encuentran en el sistema en cualquier tiempo dado.
- Probabilidad de bloqueo (P_w): probabilidad de que un cliente que llega tenga que esperar a ser atendido.
- Utilización del servidor (U): fracción de tiempo, en promedio, que un servidor está ocupado.
- Distribución de probabilidad de estado: probabilidad de que se encuentren n clientes en el sistema de colas cuando está estable.
- Probabilidad de negación de servicio (P_i): probabilidad de que un cliente que llega no pueda entrar al sistema debido a que la cola está llena.

6.3.2. Relaciones entre medidas de rendimiento

Siendo:

λ = número promedio de llegadas por unidad de tiempo

μ = número promedio de clientes atendidos por unidad de tiempo en una estación

Podemos definir las siguientes relaciones:

$$W = W_q + \frac{1}{\mu}$$

$$L = \lambda * W$$

$$L_q = \lambda * W_q$$

7. Análisis de los datos de salida de un único sistema

7.1. Comportamiento del estado transiente y estacionario de un proceso estocástico

Sean $Y_1, Y_2, \dots$ procesos estocásticos de salida y $F_i(y|I) = P(Y_i \leq y|I)$ para $i = 1, 2, \dots$, donde y es un número real e I representa las condiciones iniciales para iniciar la simulación a tiempo 0. Llamamos a $F_i(y|I)$ distribución de estado transiente del proceso estocástico de salida a tiempo discreto i para las condiciones iniciales I . Si $F_i(y|I) \rightarrow F(y)$ cuando $t \rightarrow \infty$, para toda y y para cualquier condición inicial I , entonces, $F(y)$ se llama distribución de estado estacionario de los procesos estocásticos de salida $Y_1, Y_2, \dots$.

7.2. Tipos de simulación respecto al análisis de los datos de salida

Las operaciones disponibles al diseñar y analizar experimentos de simulación dependen del tipo de simulación. Los tipos de simulación son: terminal y no terminal.

Una simulación terminal es una en la cual hay un evento “natural” E que especifica la duración de cada corrida (réplica). El evento E generalmente ocurre en un tiempo más allá del cual no se obtiene información útil del sistema o en un tiempo en donde el sistema es “limpiado”. Este evento se especifica antes de cualquier corrida, y el tiempo de ocurrencia del mismo para una corrida es una variable aleatoria. Dado que las condiciones iniciales para una simulación terminal afectan las medidas de desempeño deseadas, estas condiciones deberían ser representativas de aquellas para el sistema real.

Una simulación no terminal es aquella para la cual no hay un evento “natural” E que especifique la duración de una corrida. Dentro de las simulaciones no terminales se tienen varios parámetros para las medidas de desempeño, estos son: parámetro de estado estacionario, parámetro de ciclo de estado estacionario, otros parámetros.

Una medida de desempeño es parámetro de estado estacionario si es característica de la distribución de estado estacionario de algún proceso estocástico de salida $Y_1, Y_2, \dots$.

Sean $Y_1, Y_2, \dots$ procesos estocásticos de salida para una simulación no terminal que no tiene una distribución de estado estacionario. Supongamos que dividimos el eje de tiempo en intervalos continuos y de igual duración llamados ciclos. Sea Y_i^c una variable aleatoria definida en el i -ésimo ciclo, y asumiendo que $Y_1^c, Y_2^c, \dots$ son comparables. Supongamos que los procesos $Y_1^c, Y_2^c, \dots$ tienen una distribución de estado estacionario F^c , tal que $Y^c \sim F^c$. Entonces, una medida de desempeño es parámetro de ciclo de estado estacionario si es característica de Y^c como $v^c = E(Y^c)$. Por lo tanto, un parámetro de ciclo de estado estacionario es un parámetro de estado estacionario del ciclo apropiado del proceso $Y_1^c, Y_2^c, \dots$.

7.3. Análisis estadístico para simulaciones terminales

7.3.1. Estimación de la media

Supongamos que queremos obtener un punto de estimación y un intervalo de confianza para la media $\mu = E[X]$, donde X es la variable aleatoria definida en una réplica. Si hacemos n réplicas independientes de la simulación, y $X_1, X_2, \dots, X_n$ son las variables aleatorias independientes distribuidas idénticamente resultantes. Podemos obtener:

$$\bar{X}_n = \frac{\sum X_i}{n}$$

Que es un punto estimador imparcial para μ , y un intervalo de confianza de $100 * (1 - \alpha)$ para μ es:

$$\bar{X}_n \pm t_{n-1, 1-\alpha/2} \sqrt{\frac{S^2(n)}{n}}$$

Llamamos a esto, procedimiento de tamaño fijo.

7.3.1.1. Obtener una precisión especificada

Una desventaja de los procedimientos de tamaño fijo basados en n réplicas es que el analista no tiene control sobre la mitad del intervalo de confianza; para n fijos, la mitad dependerá de la varianza de la población de los X_j .

A continuación desarrollaremos el número de réplicas requeridas para estimar la media $\mu = E[X]$ con un error específico. Comenzamos definiendo dos formas de medir el error en el estimador $\bar{X}$.

Si el estimador $\bar{X}$ es aquel tal que $|\bar{X} - \mu| = \beta$, entonces decimos que $\bar{X}$ tiene un error absoluto de β , con una probabilidad de $1 - \alpha$. Supongamos que hemos construido un intervalo de confianza para μ basado en un número fijo de n réplicas. Si asumimos que nuestro estimador de la varianza poblacional no cambiará al aumentar el número de réplicas, el número total de réplicas, $n_a^*(\beta)$, requerido para obtener un error absoluto de β es:

$$n_a^*(\beta) = \min \left\{ i \geq n : t_{i-1, 1-\alpha/2} \sqrt{\frac{S^2(n)}{i}} \leq \beta \right\}$$

Otra forma de medir el error en $\bar{X}$ es si el estimador $\bar{X}$ es aquel tal que $|\bar{X} - \mu|/|\mu| = \gamma$, entonces decimos que $\bar{X}$ tiene un error relativo de γ , con una probabilidad de $1 - \alpha$. Supongamos que hemos construido un intervalo de confianza para μ basado en un número fijo de n réplicas. Si asumimos que nuestros estimadores de la varianza poblacional y la media poblacional no cambiarán al aumentar el número de réplicas, el número total de réplicas, $n_r^*(\gamma)$, requerido para obtener un error relativo de γ es:

$$n_r^*(\gamma) = \min \left\{ i \geq n : t_{i-1, 1-\alpha/2} \frac{\sqrt{\frac{S^2(n)}{i}}}{|\bar{X}(n)|} \leq \frac{\gamma}{1 + \gamma} \right\}$$

La dificultad al utilizar la ecuación de $n_r^*(\gamma)$ directamente para obtener un estimador de $\bar{X}$ con un error relativo de γ es que $\bar{X}(n)$ y $S^2(n)$ podrían no ser estimadores precisos de sus correspondiente parámetros de población. Si $n_r^*(\gamma)$ es más grande que el número de réplicas requeridas, entonces, un número significativo de réplicas innecesarias se pueden haber producido, desperdiciando recursos computacionales. Contrariamente, si $n_r^*(\gamma)$ es muy chico, el estimador de $\bar{X}$ basado en $n_r^*(\gamma)$ réplicas podría no ser preciso. Por esto se utiliza un procedimiento secuencial (nuevas réplicas son agregadas una a la vez) para obtener un estimador de μ con un error relativo específico que solo tomas tantas réplicas como se necesiten.

Para realizar el procedimiento secuencial, elegimos un número inicial de réplicas $n_0 \geq 2$, y sea $\delta(n, \alpha) = t_{n-1, 1-\alpha/2} \sqrt{\frac{S^2(n)}{n}}$ el intervalo de confianza de mitad de tamaño, hacemos:

1. Hacer n_0 réplicas de la simulación y fijar $n = n_0$.
2. Computar $\bar{X}(n)$ y $\delta(n, \alpha)$ de $X_1, X_2, \dots, X_n$.

3. Si $\delta(n, \alpha)/|\bar{X}(n)| \leq \frac{\gamma}{1+\gamma}$, usar $\bar{X}(n)$ como punto de estimación de μ y parar. Si no reemplazar a n por $n + 1$, hacer una réplica adicional y volver al paso 1.

7.3.2. Eligiendo condiciones iniciales

Las medidas de rendimiento para una simulación terminal dependen explícitamente del estado del sistema a tiempo 0, por lo que se debe tener cuidado al elegir las condiciones iniciales.

8. Medidas múltiples de rendimiento

Supongamos que I_s es un intervalo de confianza de $100(1 - \alpha)$ por ciento para la medida de rendimiento μ_s ($s = 1, 2, \dots, k$) de una simulación terminal o no terminal. Entonces, la probabilidad de que todos los k intervalos contengan simultáneamente sus respectivas medidas satisface:

$$P(\mu_s \in I_s \forall s = 1, 2, \dots, k) \geq 1 - \sum_{s=1}^k \alpha_s$$

Este resultado se conoce como inecuación de Bonferroni. Esta inecuación tiene un problema, supongamos que se construye un intervalo de confianza de 90 por ciento de confianza, esto es $\alpha_s = 0,1$ para todas las s para diez medidas de rendimiento distintas. Entonces, la probabilidad de que cada uno de los diez intervalos contenga su medida de rendimiento verdadera sólo puede ser más grande o igual a cero. Por lo tanto, no se puede tener mucha confianza al sacar conclusiones. Para solucionar el problema anterior de cuando k es chico, si uno quiere el nivel de confianza asociado a k intervalos, que tengan al menos una confianza de $100(1 - \alpha)$ por ciento, elegimos los α_s tal que $\sum_{s=1}^k \alpha_s = \alpha$. Se recomienda que k no sea mayor que 10.

9. Comparando configuraciones de sistemas alternativos

9.1. Intervalos de confianza para la diferencia entre las medidas de rendimiento de dos sistemas

Para $i = 1, 2$, sea $X_{i1}, X_{i2}, \dots, X_{in_i}$, n_i observaciones independientes distribuidas idénticamente del sistema i , y sea $\mu_i = E(X_{ij})$ el valor de interés, queremos construir un intervalo de confianza para $\xi = \mu_1 - \mu_2$.

9.1.1. Intervalo de confianza t-apareado

Este método no requiere que X_{1j} y X_{2j} sean independientes. Si $n_1 = n_2 = n$, podemos emparejar X_{1j} con X_{2j} para definir $Z_j = X_{1j} - X_{2j}$, para $j = 1, 2, \dots, n$.

Entonces, los Z_j son variables aleatorias independientes distribuidas idénticamente y $E(Z_j) = \xi$. Por lo tanto, podemos hacer:

$$\bar{Z}(n) = \frac{\sum_{j=1}^n Z_j}{n}$$

$$\widehat{Var}[\bar{Z}(n)] = \sum_{j=1}^n \frac{[Z_j - \bar{Z}(n)]^2}{n * (n - 1)}$$

Y formamos el intervalo de confianza para ξ :

$$\bar{Z}(n) \pm t_{n-1, 1-\alpha/2} \sqrt{\widehat{Var}[\bar{Z}(n)]}$$

9.1.2. Intervalo de confianza de Welch

Este método no empareja las observaciones de dos sistemas, pero requiere que X_{1j} sea independiente de X_{2j} , sin embargo, n_1 puede ser distinto de n_2 .

Hacemos para $i = 1, 2$:

$$\bar{X}_i(n_i) = \frac{\sum_{j=1}^{n_i} X_{ij}}{n_i}$$

$$S_i^2(n_i) = \sum_{j=1}^{n_i} \frac{[X_{ij} - \bar{X}_i(n_i)]^2}{n_i - 1}$$

Luego, usamos como un intervalo de confianza para ξ :

$$\bar{X}_1(n_1) - \bar{X}_2(n_2) \pm t_{f, 1-\alpha/2} \sqrt{\frac{S_1^2(n_1)}{n_1} + \frac{S_2^2(n_2)}{n_2}}$$

Siendo $\hat{f} = g(s_1, s_2, n_1, n_2)$.

9.2. Intervalos de confianza para comparar más de dos sistemas

9.2.1. Método de ranking y selección

9.2.1.1. Seleccionar el mejor de k sistemas

Sea X_{ij} , una variable aleatoria independiente de interés de la j -ésima réplica del i -ésimo sistema, y sea $\mu_i = E(X_{ij})$.

Sea μ_{iL} , el L -ésimo más chico de los μ_i , tal que $\mu_1 \leq \mu_2 \leq \dots \leq \mu_{ik}$. El objetivo es seleccionar el sistema con el μ_1 más chico.

Sea CS el evento selección correcta. Queremos que $P(CS) \geq P^*$, provisto por $\mu_1 - \mu_2 \geq d^*$, donde $P^* > \frac{1}{k}$ y la cantidad de indiferencia es $d^* > 0$, ambos parámetros especificados por el analista.

En la primera etapa hacemos $n_0 \geq 2$ réplicas de cada uno de los k sistemas y definimos para $i = 1, 2, \dots, k$:

$$\bar{X}_i^{(1)}(n_0) = \frac{\sum_{j=1}^{n_0} X_{ij}}{n_0}$$

$$S_i^2(n_0) = \sum_{j=1}^{n_0} \frac{[X_{ij} - \bar{X}_i^{(1)}(n_0)]^2}{n_0 - 1}$$

Luego, computamos el tamaño de la muestra N_i para el sistema i :

$$N_i = \max \left\{ n_0 + 1, \left\lceil \frac{h_1^2 S_i^2(n_0)}{(d^*)^2} \right\rceil \right\}$$

Donde h_1 es una constante que se obtiene por tabla.

A continuación, hacemos $N_i - n_0$ réplicas más del sistema i , y obtenemos las medidas de la segunda etapa:

$$\bar{X}_i^{(2)}(N_i - n_0) = \frac{\sum_{j=n_0+1}^{N_i} X_{ij}}{N_i - n_0}$$

Y la media de tamaño ponderado es:

$$\bar{X}_i(N_i) = \left(W_{i1} * \bar{X}_i^{(1)}(n_0) \right) + \left(W_{i2} * \bar{X}_i^{(2)}(N_i - n_0) \right)$$

Luego, seleccionamos el sistema con el más chico $\bar{X}_i(N_i)$.

9.2.1.2. Seleccionar un subconjunto de tamaño n que contiene al mejor de k sistemas

El procedimiento es similar al de ‘seleccionar el mejor de k sistemas’ excepto que en el cálculo de N_i se reemplaza a h_1 por h_2 . Además, $P^* > m/k$ y $\mu_{i1} - \mu_{i2} \geq d^*$.

9.2.1.3. Seleccionar los m mejores de k sistemas

El procedimiento es similar al de ‘seleccionar un subconjunto de tamaño n que contiene al mejor de k sistemas’ excepto que en el cálculo de N_i se reemplaza a h_2 por h_3 . Además, $P^* > m! * (k - m)! / k!$ y $\mu_{m+1} - \mu_m \geq d^*$.

10. Método de media de lotes

Este método se utiliza para el análisis de las simulaciones no terminales. Trabaja de la siguiente manera:

1. Correr la simulación el tiempo suficiente como para remover cualquier efecto transiente y proveer una cantidad de datos representativos del estado estacionario.
2. Dividir la duración restante de la corrida de simulación en sub-intervalos de tiempo correspondientes a “lotes” de datos.
3. Computar medidas de rendimiento promedio para cada lote, y usar técnicas clásicas para desarrollar estimadores, tratando las medias de lotes como réplicas independientes.

Los lotes sucesivos poseen cierta auto-correlación. Una manera de reducir esto es eliminar ciertos lotes (por ejemplo, eliminar los lotes pares o impares), aunque esto reduce el número de observaciones independientes, lo que resulta en intervalos de confianza más débiles.

11. Números aleatorios comunes

Si nuestro objetivo es determinar diferencias en las respuestas de un sistema debido al cambio en algún parámetro del sistema, es intuitivamente razonable comparar la respuesta del sistema bajo las mismas circunstancias. Esto implica utilizar los mismos números aleatorios para generar los tiempos de arribo y partida para las corridas a comparar.

Si $\bar{x}_1$ es el tiempo de espera promedio obtenido a través de una simulación con un valor de retraso 1; y $\bar{x}_2$ es el valor correspondiente para un valor de retraso 2, entonces, la varianza de la diferencia será:

$$var(\bar{x}_1 - \bar{x}_2) = var(\bar{x}_1) - var(\bar{x}_2) + (2 * cov(\bar{x}_1, \bar{x}_2))$$

Si variables aleatorias comunes son utilizadas, habrá correlación entre las dos respuestas $\bar{x}_1$ y $\bar{x}_2$, y la varianza de su diferencia será reducida si el término de la covarianza es positivo.

Capítulo 1: Modelado de Simulación Básico (Law & Kelton)

La naturaleza de la simulación

Sistema: empresa o proceso de interés a modelizar.

Modelo: representación del sistema en términos de relaciones cuantitativas y lógicas.

Aplicaciones:

- ✓ Diseño y análisis de sistemas de fabricación.
- ✓ Evaluar requerimientos de hardware y software para un sistema informático.
- ✓ Evaluar nuevos sistemas de armas o tácticas militares.
- ✓ Determinar políticas de pedidos para un sistema de inventarios.
- ✓ Diseñar sistemas de comunicaciones y protocolos de mensajes para ellos.
- ✓ Diseñar y operar instalaciones de transporte.
- ✓ Evaluar diseños para organizaciones de servicios.
- ✓ Analizar sistemas financieros o económicos.

Sistemas, modelos y simulación

Un sistema se define como una colección de entidades que actúan e interactúan juntos hacia el cumplimiento de un fin lógico. Definimos el estado de un sistema como una colección de variables necesarias para describir un sistema en un momento determinado, relativos a los objetivos de estudio.

Los sistemas se categorizan en dos tipos: discretos o continuos. Un sistema discreto es aquel en el que las variables de estado cambian instantáneamente en puntos separados del tiempo. En un sistema continuo en cambio las variables de estado cambian continuamente con respecto al tiempo.

Diferentes maneras en que un sistema puede ser estudiado:

- ✓ Experimentos con el sistema real vs. Experimentos con un modelo del sistema: si es posible alterar el sistema físico y luego dejar que opere bajo las nuevas condiciones, es probable que sea conveniente hacerlo, porque en este caso no hay duda acerca de si lo que estudiamos es relevante. Sin embargo, rara vez es posible hacer esto. Por esto, es necesario construir un modelo como una representación del modelo y estudiarlo como un sustituto del sistema real.
- ✓ Modelos físicos vs. Modelos matemáticos: los modelos físicos son construcciones en escala reducida o simplificada del sistema real para estudiar en ellos su comportamiento. Los modelos matemáticos representan un sistema en términos de relaciones lógicas y cuantitativas que son luego manipuladas y modificadas para ver como el sistema reacciona
- ✓ Solución analítica vs. Simulación: si las relaciones que componen el modelo son suficientemente simples, puede ser posible utilizar métodos matemáticos para obtener información exacta sobre cuestiones de interés, lo que se llama solución analítica. Muchos sistemas son demasiados complejos para ser estudiados analíticamente, y deben ser estudiados por medio de la simulación. En una simulación, usamos la computadora para evaluar un modelo numéricamente, y los datos se recogen con el fin de estimar las características del modelo.

Clasificación de los modelos de simulación:

- ✓ Estáticos vs. Dinámicos: un modelo de simulación estático es una representación de un sistema en un momento determinado, o uno que puede ser utilizado para representar un sistema en el que el tiempo simplemente no juega ningún papel. Un modelo de simulación dinámica representa un sistema a medida que evoluciona en el tiempo.
- ✓ Estocásticos vs. Determinísticos: Si un modelo de simulación no contiene componentes probabilísticas (es decir aleatorias) se conoce como determinístico, en estos modelos la salida se "determina" una vez que se

especifica el conjunto de relaciones (ecuaciones) y los valores de entrada. En cambio los modelos estocásticos contienen variables aleatorias de entrada sujetas a una distribución probabilística de algún tipo.

- ✓ Continuos vs. Discretos: definimos los modelos de simulación discreta y continua de manera análoga a la forma en que los sistemas discretos y continuos se definieron anteriormente.

Simulación de Eventos Discretos:

La simulación de eventos discretos comprende el modelado de un sistema a medida que este evoluciona a través del tiempo por medio de una representación en la cual las variables de estado cambian instantáneamente en puntos separados en el tiempo. Estos puntos en el tiempo son aquellos en los cuales un evento ocurre, donde un evento se define como una ocurrencia instantánea que puede cambiar el estado del sistema.

Mecanismo de Avance del Tiempo

Debido a la naturaleza dinámica de los modelos de simulación de eventos discretos, tenemos que realizar un seguimiento del valor actual del tiempo simulado a medida que avanza la simulación, y también necesitamos un mecanismo para avanzar el tiempo simulado de un valor a otro. Llamamos *reloj* de la simulación a la variable de un modelo de simulación que contiene el valor actual del tiempo simulado. La unidad del reloj nunca se enuncia explícitamente y se asume que está en las mismas unidades que los parámetros de entrada.

Existen dos enfoques para el mecanismo de avance del tiempo:

- ✓ **Avance del tiempo al siguiente evento**: Con este enfoque el reloj de la simulación se inicializa a cero y se determinan los tiempos de ocurrencia de eventos futuros, luego el reloj se avanza al tiempo de ocurrencia del evento futuro más próximo, en este punto el estado del sistema se actualiza para determinar que un evento ha ocurrido y los tiempos de futuros eventos también se actualizan. Este proceso continua hasta que se cumple con una condición de parada pre especificada.
- ✓ **Avance del tiempo a incrementos fijos**: La diferencia con el método anterior es que este enfoque no saltea periodos de inactividad en el sistema, lo que supone una mayor cantidad de cómputo.

Componentes y organización de un modelo de simulación de eventos discretos

- ✓ Estado del sistema: el conjunto de variables de estado necesarias para describir el sistema en un momento dado.
- ✓ Reloj de simulación: una variable que indica el valor actual del tiempo simulado.
- ✓ Lista de eventos: una lista que contiene la próxima vez en el que cada tipo de evento ocurrirá.
- ✓ Contadores estadísticos: variables usadas para almacenar información estadística sobre el rendimiento del sistema.
- ✓ Rutina de inicialización: un sub-programa que inicializa el modelo de simulación en el tiempo cero.
- ✓ Rutina de tiempo: un sub-programa que determina el siguiente evento de la lista de eventos y luego avanza el reloj de simulación al momento en que ocurre ese evento.
- ✓ Rutina de evento: un sub-programa que actualiza el estado del sistema cuando un tipo particular de evento ocurre (hay una rutina de evento por cada tipo de evento).
- ✓ Rutinas de biblioteca: un conjunto de sub-programas utilizados para generar observaciones aleatorias a partir de distribuciones de probabilidad que fueron determinadas como parte del modelo de simulación.
- ✓ Generador de informes: un sub-programa que calcula estimaciones de las medidas de rendimiento deseadas y elabora un informe cuando la simulación finaliza.

- ✓ Programa principal: un sub-programa que invoca la rutina de tiempo para determinar el siguiente evento y luego transfiere el control a la correspondiente rutina de evento para actualizar el estado del sistema apropiadamente. También controla la terminación e invoca al generador de informes cuando la simulación acaba.

Simulación de un Sistema de Colas de un solo Servidor (M/M/1):

En un sistema de colas de un solo servidor, los tiempos entre arribos $A_1, A_2, \dots, A_n$ (de cada cliente al sistema) son variables aleatorias IID (independientes e idénticamente distribuidas). Un cliente que arriba y encuentra al servidor desocupado se atiende inmediatamente, y los tiempos de servicio $S_1, S_2, \dots, S_n$ (de cada cliente) son también variables aleatorias IID independientes de los tiempos de arribo. Si un cliente arriba y encuentra al servidor ocupado se une al final de cola. Al producirse una partida (un cliente completa el servicio) el servidor elige un cliente de la cola según la disciplina FIFO. La simulación comenzará sin clientes en el sistema y el servidor en estado desocupado. El sistema se simula hasta que un número fijo (n) de clientes hayan completados sus demoras en cola, es decir cuando el n -ésimo cliente entre en servicio.

Medidas de Rendimiento: Para medir el rendimiento de este sistema observamos las estimaciones de tres parámetros (más un parámetro opcional que es $w(n)$):

- ✓ Demora promedio esperada en cola de los n clientes. Llamada $d(n)$.
- ✓ Número de clientes promedio esperado en la cola. Denotado por $q(n)$.
- ✓ Utilización del servidor. Denominada $u(n)$.
- ✓ Demora promedio esperada en el sistema de los n clientes. Llamada $w(n)$.

Demora promedio esperada en cola de los "n-clientes":

La demora promedio en una corrida determinada de la simulación es considerada propiamente como una variable aleatoria en sí. Lo que queremos estimar, $d(n)$, es el valor esperado para esta variable aleatoria. $d(n)$ es el promedio de una gran número de demoras promedio de n clientes. A partir de una sola corrida de la simulación podemos estimar este parámetro a través de:

$$\hat{d}(n) = \frac{\sum_{i=1}^n D_i}{n}$$

Esta fórmula es el promedio de las n demoras que fueron obtenidas durante la simulación.

Este estimador está basado en una muestra de tamaño 1 ya que estamos haciendo solamente una sola corrida de la simulación. Un estimador de este tipo no tendrá demasiada precisión, pues el sistema seguramente se encuentra en estado *transitorio*.

Es un ejemplo de una estadística de tiempo discreto.

Número de clientes promedio esperado en la cola:

Este promedio se toma sobre el periodo de tiempo necesarios para observar las n demoras que definen nuestra regla de parada. Esta es una clase diferente de promedio que el anterior, ya que se toma sobre el tiempo (continuo) en lugar de los clientes (discreto).

Definimos $Q(t)$ como el número de clientes en cola en el momento t (para cualquier $t \geq 0$) y $T(n)$ como el tiempo requerido para observar n demoras en cola. Para cualquier momento t entre 0 y $T(n)$, $Q(t)$ es no negativo. Si llamamos p_i a la proporción esperada (entre 0 y 1) del tiempo en que $Q(t)$ es igual a i , una definición de $q(n)$ sería:

$$q(n) = \sum_{i=0}^{\infty} i p_i$$

Para estimar $q(n)$ en una simulación, simplemente reemplazamos p_i con sus respectivas estimaciones y obtenemos:

$$\hat{q}(n) = \sum_{i=0}^{\infty} i \hat{p}_i$$

Donde $\hat{p}_i$ es la proporción observada del tiempo en que hubo i clientes en la cola (en la simulación).

Sin embargo una manera más sencilla de obtener $\hat{q}(n)$ es mediante algunas consideraciones geométricas. Si llamamos T_i al tiempo total durante la simulación en que la cola es de tamaño i , luego:

$$T(n) = \sum_{i=0}^n T_i = T_0 + T_1 + T_2 + \dots + T_n \text{ y } P_i = T_i/T(n)$$

Y el estimador puede escribirse como:

$$\hat{q}(n) = \frac{\sum_{i=0}^{\infty} i T_i}{T(n)}$$

La sumatoria en el numerador de la ecuación anterior es solo el área bajo la curva de $Q(t)$, que puede escribirse como una integral de 0 hasta $T(n)$, quedando finalmente la expresión:

$$\hat{q}(n) = \frac{\int_0^{T(n)} Q(t) dt}{T(n)}$$

Es un ejemplo de una estadística de tiempo continuo.

Utilización esperada del servidor:

La utilización esperada del servidor es la proporción esperada de tiempo durante la simulación en que el servidor está ocupado y por eso es un número entre 0 y 1. El estimador $\hat{u}(n)$ es la proporción observada de tiempo durante la simulación en que el servidor está ocupado. Para esto definimos la "función ocupado" $B(t)$.

$$B(t) = \begin{cases} 1 & \text{si el servidor está ocupado en el tiempo } t \\ 0 & \text{si el servidor está desocupado en el tiempo } t \end{cases}$$

De esta manera $\hat{u}(n)$ puede expresarse como la proporción de tiempo en que $B(t)$ es igual a 1.

$$\hat{u}(n) = \frac{\int_0^{T(n)} B(t) dt}{T(n)}$$

El numerador puede ser visto como el área bajo la función $B(t)$ durante el curso de la simulación.

$\hat{u}(n)$ es el promedio continuo de la función $B(t)$. La integral de $B(t)$ puede fácilmente ser acumulada por la suma de las áreas de los rectángulos. Las estadísticas de uso son muy informativos en la identificación de cuellos de botella o exceso de capacidad.

Es un ejemplo de una estadística de tiempo continuo.

Demora o Tiempo de espera promedio esperado en el sistema (cola + servidor):

Esta medida se define como el intervalo de tiempo desde el instante que un cliente arriba a la cola hasta el instante en que el cliente completa el servicio y parte.

El estimador usual de $w(n)$ sería:

$$\hat{w}(n) = \frac{\sum_{i=1}^n D_i}{n} + \frac{\sum_{i=1}^n S_i}{n} = \hat{d}(n) + \bar{S}(n)$$

Donde S_i es el tiempo de espera de los n clientes en el servidor y $\bar{S}(n)$ es el promedio de los n tiempos de servicio de los clientes. Ya que el tiempo de servicio medio o esperado $E(S)$ es conocido un estimador alternativo sería $\tilde{w}(n) = \hat{d}(n) + E(S)$

En casi todas las simulaciones de colas $\tilde{w}(n)$ será mejor que $\hat{w}(n)$. Ambos son estimadores no sesgados.

Eventos y variables de estado: Los eventos de este sistema son el arribo de un cliente y la partida de un cliente. Las variables de estado necesarias para estimar

$d(n)$, $q(n)$ y $u(n)$ son el estado del servidor, el número de clientes en cola, el tiempo de arribo de cada cliente en cola y el tiempo del último evento.

Observaciones:

- ✓ El elemento clave en la dinámica de una simulación es la interacción entre el reloj de la simulación y la lista de eventos.
- ✓ Mientras se procesa un evento, no transcurre el tiempo de simulación.
- ✓ A veces es fácil pasar por alto las contingencias que parecen fuera de lo común, pero que sin embargo hay que tener en cuenta.
- ✓ En algunas simulaciones puede suceder que 2 o más entradas en la lista de eventos empatan en menor, y deba incorporarse una regla de decisión para romper empates, que afectará el resultado de la simulación.

Reglas de interrupción alternativas

La simulación puede terminar:

- ✓ Cuando el número de clientes atendidos llega a una determinada cantidad fija. El valor final del reloj de la simulación es una variable aleatoria.
- ✓ Cuando el reloj llega a una cantidad fija de tiempo. El número de clientes atendidos es una variable aleatoria.

Determinando los eventos y variables

En el método de eventos gráficos, los eventos propuestos, cada uno representado por un nodo, están conectados por arcos dirigidos que representan cómo los eventos se pueden programar de otros eventos y de ellos mismos. Los eventos gráficos conectan el conjunto propuesto de eventos por los arcos que indican el tipo de programación de eventos que pueden ocurrir. Las flechas lisas gruesas indican que un evento al final de la flecha se puede programar desde el evento en el comienzo de la flecha en una cantidad no nula de tiempo, y la flecha dentada delgada indica que el evento en su extremo está programado inicialmente.

Uno de los usos de los gráficos de eventos es simplificar la estructura de eventos de una simulación mediante la eliminación de eventos innecesarios. Hay varias reglas que permiten la simplificación, y una de ellas es que si un nodo de evento tiene arcos entrantes que son todos delgados y lisos, este evento puede ser eliminado del modelo y su acción integrada en los eventos que se programan en tiempo cero.

Otra regla tiene que ver con la inicialización. El gráfico de eventos se descompone en componentes fuertemente conectados, dentro de cada uno de los cuales es posible viajar desde cada nodo a todos los demás nodos siguiendo los arcos en sus direcciones indicadas. La regla de inicialización establece que en cualquier componente fuertemente conectado de nodos que no tenga arcos entrantes de otros nodos de eventos fuera del componente, debe haber al menos un nodo que se programa inicialmente.

Simulación distribuida

En los últimos años la tecnología informática ha permitido que las computadoras o procesadores individuales se asocien entre sí en entornos de computación paralela o distribuida. En estos tipos de entornos, puede ser posible distribuir diferentes partes de una tarea computacional a través de procesadores individuales que operan al mismo tiempo y por lo tanto reducir el tiempo total para completar la tarea.

Hay muchas formas posibles de dividir una simulación dinámica para distribuir su trabajo sobre diferentes procesadores:

- ✓ *Asignar las distintas funciones de apoyo a diferentes procesadores.* La lógica de ejecución de la simulación sigue siendo secuencial, pero el programa principal de la simulación puede delegar la ejecución de las funciones de soporte a otros procesadores y seguir adelante con su trabajo.

- ✓ *Descomponer el modelo en distintos sub-modelos*, que luego son asignados a diferentes procesadores para la ejecución. Los procesadores deben comunicarse entre sí siempre que sea necesario para mantener las relaciones lógicas correctas entre los sub-modelos.

Pasos en un estudio de simulación

1. *Formular el problema y planificar el estudio*: todo estudio debe comenzar con una declaración clara de los objetivos generales del estudio y las cuestiones específicas que se abordarán.
2. *Recolectar datos y definir un modelo*: información y datos deben recolectarse del sistema de interés y utilizarse para especificar los procedimientos operativos y distribuciones de probabilidad de las variables aleatorias utilizadas en el modelo.
3. *Validar*: en la construcción del modelo, es imperativo para los modeladores involucrar en el estudio a las personas que están íntimamente familiarizadas con las operaciones del sistema real.
4. *Construir un programa de computación y verificar*: el modelador de la simulación debe decidir si se debe programar el modelo en un lenguaje de propósito general o en un lenguaje de simulación de diseño especial.
5. *Hacer corridas piloto*: se hacen pruebas piloto del modelo verificado.
6. *Validar*: las pruebas piloto pueden usarse para probar la sensibilidad de las salidas del modelo a pequeños cambios en un parámetro de entrada.
7. *Diseñar experimentos*: hay que decidir qué diseño de sistema simular si hay más de una alternativa que pueda razonablemente simularse.
8. *Hacer corridas de producción*: se hacen corridas de producción para proporcionar datos de rendimiento sobre los diseños de los sistemas de interés.
9. *Analizar los datos de salida*: se usan técnicas estadísticas para analizar los datos de salida de las corridas.
10. *Documentar presentar e implementar los resultados*: es importante documentar los supuestos que entraron en el modelo, así como el propio programa informático.

Otros tipos de simulación

- ✓ *Simulación continua*: se refiere a la modelización a lo largo del tiempo de un sistema por una representación en la que las variables de estado cambian continuamente con respecto al tiempo. Involucra ecuaciones diferenciales que dan las relaciones de las tasas de variación de las variables de estado con el tiempo.
- ✓ *Simulación combinada discreta-continua*: puesto que algunos sistemas no son ni completamente discretos ni completamente continuo, puede surgir la necesidad de construir un modelo con aspectos tanto de simulación de eventos discretos y continuos.
- ✓ *Simulación de Monte Carlo*: es un esquema de empleo de números aleatorios que se utiliza para solucionar determinados problemas estocásticos o deterministas en donde el paso del tiempo no juega ningún papel sustantivo.

Ventajas, desventajas y dificultades de la simulación

Ventajas:

- ✓ Muchos sistemas complejos no pueden describirse con precisión mediante un modelo matemático que puede evaluarse analíticamente. Por lo tanto, una simulación es a menudo el único tipo de investigación posible.
- ✓ Permite estimar el rendimiento de un sistema existente bajo un conjunto de condiciones de operación proyectados.

- ✓ Diseños alternativos del sistema propuesto se pueden comparar a través de la simulación para poder ver los que mejor se adaptan a los requerimientos especificados.
- ✓ En una simulación podemos mantener mejor control sobre las condiciones experimentales de lo que generalmente sería posible cuando experimentamos con el propio sistema.
- ✓ Permite estudiar un sistema con un horizonte temporal largo en tiempo comprimido, o bien estudiar los pormenores del funcionamiento de un sistema en tiempo expandido.

Desventajas:

- ✓ Cada corrida de un modelo de simulación estocástico produce solo estimaciones de las verdaderas características del modelo para un conjunto particular de parámetros de entrada.
- ✓ Los modelos de simulación suelen ser costosos y requieren mucho tiempo para desarrollarlos.
- ✓ El gran volumen de números producidos por un estudio de simulación o el impacto persuasivo de una animación realista crea a menudo una tendencia a poner mayor confianza en los resultados de un estudio que la que se justifica.

Capítulo 9: Análisis de datos de salida para un sistema único

9.1 Introducción:

En muchos estudios de simulación se invierte una gran cantidad de dinero y tiempo en un modelo de desarrollo y programación, pero se realiza poco esfuerzo en analizar los datos de salida de la simulación apropiadamente. De hecho, un modo común de operación es hacer una sola corrida de la simulación de longitud arbitraria y luego tratar a las estimaciones de la simulación como las características del modelo verdadero. Ya que las muestras aleatorias de distribuciones de probabilidad son típicamente usadas para llevar adelante un modelo de simulación a través del tiempo, estas estimaciones dependen de los valores particulares de variables aleatorias que pueden sufrir variaciones. Como resultado, estas estimaciones en una corrida particular de la simulación, pueden diferir de las verdaderas características del modelo. El efecto neto es que hay una gran probabilidad de cometer errores en las inferencias sobre el sistema bajo estudio. Históricamente, hay algunas razones por las cuales los analistas de los datos de salida no se manejan de manera apropiada. Primero, los usuarios generalmente tienen la impresión que la simulación consiste en programación complicada. Consecuentemente, muchos estudios de simulación comienzan con la construcción de un modelo heurístico y codificación, y terminan con una sola corrida del estudio de simulación que produce “las respuestas”. De hecho, **la simulación es un experimento de muestreo estadístico usando computadoras**. En consecuencia, si los resultados de un estudio de simulación tienen un significado, hay que utilizar apropiadas **técnicas estadísticas para diseñar y analizar experimentos estadísticos**. Una segunda razón para inadecuados análisis estadísticos es que los procesos de salida de simulaciones virtuales son **no estacionarios y autocorrelacionados** (ej. Los clientes que llegan afectan a los que llegaran). Por esta razón las técnicas estadísticas basadas en observaciones independientes e idénticamente distribuidas (IID) no son directamente aplicables.

Ahora vamos a describir más precisamente la naturaleza aleatoria de la salida de una simulación. Sea $Y_1, Y_2, \dots, Y_m$ las salidas de una sola corrida de simulación de un proceso estocástico. Por ejemplo, Y_i podría ser el rendimiento (producción) en la i -ésima hora en una empresa de manufactura. Las Y_i son variables aleatorias que en general no son IID. En el caso de nuestro ejemplo, no son independientes ya que la producción de una determinada hora depende de la hora anterior. Sean $y_{11}, y_{12}, \dots, y_{1m}$ el resultado de realizar una corrida de simulación de longitud m de m observaciones utilizando los números aleatorios $u_{11}, u_{12}, \dots, u_{1m}$ (el i -ésimo número aleatorio que es utilizado en la j -ésima corrida se denota u_{ji}). Si realizamos otra corrida de la simulación con una diferente secuencia de números aleatorios $u_{21}, u_{22}, \dots, u_{2m}$, entonces obtendremos otros valores $y_{21}, y_{22}, \dots, y_{2m}$ de las variables aleatorias $Y_1, Y_2, \dots, Y_m$. Suponga que realizamos n replicas independientes de la simulación (se utilizan diferentes números aleatorios para cada réplica, se reinician los contadores estadísticos para cada réplica y cada replica utiliza las mismas condiciones iniciales) de longitud m , obteniendo como resultado las siguientes observaciones.

Secuencia 1:	$y_{11}, y_{12}, \dots, y_{1i}, \dots, y_{1m}$
Secuencia 2:	$y_{21}, y_{22}, \dots, y_{2i}, \dots, y_{2m}$
	$\vdots \quad \vdots \quad \quad \quad \vdots \quad \quad \quad \vdots$
Secuencia n:	$y_{n1}, y_{n2}, \dots, y_{ni}, \dots, y_{nm}$

Las observaciones de una réplica particular (fila) no son IID. (Hay problemas de independencias porque hay correlación). Sin embargo, si observamos $y_{1i}, y_{2i}, \dots, y_{ni}$ (de la i -ésima columna) son observaciones IID de la

variable aleatoria Y_i , para $i=1,2,\dots, m$. Esta independencia de corridas cruzadas es la clave para los simples métodos de análisis de datos de salida que se describen en las siguientes secciones. Entonces, toscamente hablando, la clave del análisis de salida es usar las observaciones y_{ji} ($i=1,2,\dots, m$; $j=1,2,\dots, n$) para hacer inferencias sobre variables aleatorias $Y_1, Y_2, \dots, Y_m$.

9.2 Comportamiento transiente y estado estacionario de un proceso estocástico:

Considerar la salida de un proceso estocástico $Y_1, Y_2, \dots, Y_n$. Sea $F_i(y|I) = P(Y_i \leq y | I)$ para $i=1,2,\dots, n$, donde y es un número real e I representa las condiciones iniciales utilizadas para comenzar la simulación en tiempo cero. (La probabilidad condicional $P(Y_i \leq y | I)$ es la probabilidad que el evento $Y_i \leq y$ ocurre dadas las condiciones iniciales I). Para un sistema de manufactura, I puede representar el número de trabajos pendientes y si la máquina está libre u ocupada en tiempo cero. Llamamos **$F_i(y|I)$ la distribución transiente** de un proceso de salida en un tiempo discreto i para condiciones iniciales I . (En la etapa transiente son muy importantes las condiciones iniciales). Las funciones de densidad para distribuciones transientes correspondientes a las variables aleatorias pueden variar de una réplica a otra. Hay un cambio permanente en la distribución de probabilidad (ley de los grandes números).

Para valores fijos de y e I , las probabilidades $F_1(y|I), F_2(y|I), \dots$ son solo números. Si $F_i(y|I) \rightarrow F(y)$ cuando $i \rightarrow \infty$ para toda y y para cualquier condición inicial I , **$F(y)$ es llamada distribución en estado estacionario** de los procesos de salida $Y_1, Y_2, \dots, Y_n$. Estrictamente hablando, la distribución en estado estacionario $F(y)$ solo se obtiene cuando $i \rightarrow \infty$. En la práctica, sin embargo, en general habrá un tiempo, $K+1$, en el cual las distribuciones, desde este punto en adelante, serán aproximadamente las mismas. El tiempo estacionario se dice que comienza en un tiempo $K+1$. Notar que el estado estacionario no implica que las variables aleatorias $Y_{K+1}, Y_{K+2}, \dots, Y_{K+n}$ tomarán el mismo valor en una corrida particular de simulación sino que significa que tendrán aproximadamente la misma distribución. Además, estas variables aleatorias no serán independientes.

La distribución de probabilidad no varía con estado estacionario y se independiza de las condiciones iniciales.

La distribución en estado estacionario $F(y)$ no depende de las condiciones iniciales I , sin embargo la velocidad de convergencia de la distribución transiente $F_i(y|I)$ a la $F(y)$ sí.

9.3 Tipos de simulaciones en relación con el análisis de resultados:

Las opciones disponibles para diseñar y analizar experimentos de simulación dependen del tipo de simulación. Las simulaciones pueden ser terminales o no terminales, dependiendo si hay o no una manera obvia de determinar la longitud de la corrida. Además, las medidas de rendimiento para simulaciones no terminales pueden ser de varios tipos.

Simulación $\rightarrow$ Terminal.

$\rightarrow$ No terminal $\rightarrow$ Parámetros de estado estacionario.

$\rightarrow$ Ciclos de estado estacionario.

$\rightarrow$ Otros parámetros.

Una **simulación terminal** es una para la cual existe un evento natural E , que especifica la longitud de cada corrida o réplica. Como las diferentes corridas utilizan números aleatorios independientes y la misma regla de inicialización, esto implica que las variables aleatorias comparables de distintas corridas son IID. El evento E ocurre en un punto en el tiempo en el cual no se obtiene más información útil del sistema o el sistema se limpia. Este evento debe especificarse antes de hacer las corridas y el tiempo de ocurrencia de E en una corrida particular puede ser una variable aleatoria. Como las condiciones iniciales de una simulación terminal generalmente afectan las medidas iniciales de rendimiento, estas deben ser muy representativas de lo que ocurre en el sistema real.

Una **simulación no terminal** es aquella para la que no existe evento natural E para especificar la longitud de una corrida. Una medida de rendimiento para este tipo de simulaciones es el parámetro de estado estacionario, si es una característica de la distribución de estado estacionario de algún proceso estocástico $Y_1, Y_2, \dots, Y_n$. Si una variable aleatoria Y tiene una distribución de estado estacionario, entonces podemos estar interesados en estimar el promedio de estado estacionario $v = E(Y)$.

Sean $Y_1, Y_2, \dots$ procesos estocásticos de salida para una simulación no terminal que no tiene una distribución de estado estacionario. Supongamos que dividimos el eje de tiempo en intervalos continuos y de igual duración llamados ciclos. Sea Y_i^c una variable aleatoria definida en el i -ésimo ciclo, y asumiendo que $Y_1^c, Y_2^c, \dots$ son comparables. Supongamos que los procesos $Y_1^c, Y_2^c, \dots$ tienen una distribución de estado estacionario F^c , tal que $Y^c \sim F^c$. Entonces, una medida de desempeño es parámetro de ciclo de estado estacionario si es característica de Y^c como $v^c = (Y^c)$. Por lo tanto, un parámetro de ciclo de estado estacionario es un parámetro de estado estacionario del ciclo apropiado del proceso $Y_1^c, Y_2^c, \dots$.

9.4 Análisis estadístico para simulaciones terminales:

Suponga que hacemos n replicas independientes de una simulación terminal, donde cada réplica finaliza por el evento E y comienza con las mismas condiciones iniciales. La independencia de las replicas se lleva a cabo utilizando diferentes números aleatorios para cada réplica. Asumir por simplicidad que hay una sola medida de rendimiento de interés. Sea X_j una variable aleatoria definida en la j -ésima replica con $j=1, 2, \dots, n$; las X_j son variables aleatorias IID. Para el ejemplo de un banco X_j puede ser la demora promedio de un cliente en cola. Para el sistema de inventario, el costo total promedio mensual.

9.4.1 Estimación de la media:

Suponga que queremos obtener un punto de estimación y un intervalo de confianza para la media $\mu = E(X)$, donde X es una variable aleatoria definida en una réplica como se describe arriba. Hacer n réplicas independientes de la simulación y tomando a $X_1, X_2, \dots, X_n$ como las variables aleatorias IID resultantes. Luego a partir de las X_j , obtenemos un punto de estimación imparcial para μ y un intervalo de confianza con aproximadamente $100(1-\alpha)\%$ de confianza para μ dado por:

$$\bar{X}_n \pm t_{n-1, 1-\alpha/2} \sqrt{\frac{S^2(n)}{n}} \quad (1)$$

Llamaremos este intervalo de confianza **Procedimiento de la muestra de tamaño fijo**.

Obteniendo una precisión específica:

Una desventaja del procedimiento de la muestra de tamaño fijo basada en n réplicas, es que el analista no tiene control sobre la longitud media del intervalo de confianza (o de la precisión de $\bar{X}(n)$); para n fija, la longitud media depende de $\text{Var}(X)$, la varianza de la población de los X_j . En lo que sigue discutiremos procedimientos para determinar el número de réplicas requerido para estimar la media $\mu = E(X)$, con un error o precisión específicos.

Empezamos definiendo dos caminos para medir el error en la estimación X (la dependencia de n se suprime, ya que el número de réplicas puede ser una variable aleatoria). Si la estimación de $\bar{X}$ es tal que $|\bar{X} - \mu| = \beta$ entonces decimos que $\bar{X}$ tiene un **error absoluto β** .

Supongamos que hemos construido un intervalo de confianza para μ basado en un número fijo de réplicas n . Si asumimos que nuestra estimación de la varianza $S^2(n)$ no cambiara mientras el número de réplicas sube,

una aproximación de la expresión para el número total de réplicas, $n_a^*(\beta)$, requerido para obtener el error absoluto de β está dado por:

$$n_a^*(\beta) = \min \left\{ i \geq n : t_{i-1, 1-\alpha/2} \sqrt{\frac{S^2(n)}{i}} \leq \beta \right\} \quad (2)$$

Voy aumentando i de uno en uno hasta que obtenga un valor menor a β , dicho valor de i es el número de réplicas que tengo que realizar.

Luego la estimación $\bar{X}$ basada en todas las $n_a^*(\beta)$ réplicas debería tener un error absoluto de aproximadamente β . La precisión de la ecuación (2) depende de lo cercano que está la estimación $S^2(n)$ a $\text{Var}(X)$.

Ahora discutiremos otra forma de medir el error en $\bar{X}$. Si la estimación $\bar{X}$ es tal que $|\bar{X} - \mu|/|\mu| = \gamma$, entonces decimos que $\bar{X}$ tiene un **error relativo de γ** o que el porcentaje de error en $\bar{X}$ es de $100\gamma\%$.

Suponga una vez más que construimos un intervalo de confianza de μ basado en un número fijo de réplicas n , si asumimos que nuestras estimaciones de la media y de la varianza de la población no cambian mientras el número de réplicas crece, una expresión aproximada para el número de réplicas, $n_r^*(\gamma)$ requerido para obtener el error relativo de γ dado por:

$$n_r^*(\gamma) = \min \left\{ i \geq n : t_{i-1, 1-\alpha/2} \frac{\sqrt{\frac{S^2(n)}{i}}}{|\bar{X}(n)|} \leq \frac{\gamma}{1+\gamma} \right\} \quad (3)$$

Donde $\gamma' = \gamma/(1+\gamma)$ es el error relativo ajustado necesario para obtener el error relativo actual γ . Si $n_r^*(\gamma) > n$ y si hacemos $n_r^*(\gamma)$ -n réplicas adicionales de la simulación, luego la estimación $\bar{X}$ basada en todas las $n_r^*(\gamma)$ réplicas deberían tener un error relativo de aproximadamente γ .

La dificultad de usar la ecuación (3) directamente para obtener un estimador $\bar{X}$ con un error relativo de γ es que $\bar{X}(n)$ y $S^2(n)$ pueden o no ser estimadores precisos de sus correspondientes parámetros poblacionales. Si $n_r^*(\gamma)$ es mayor que el número de réplicas realmente necesarias, entonces un número significativo de réplicas innecesarias se realizarían, resultando una pérdida de recursos computacionales. A la inversa, si $n_r^*(\gamma)$ es demasiado pequeño, entonces el estimador $\bar{X}$ basado en $n_r^*(\gamma)$ réplicas podría no ser preciso. Ahora presentamos un **procedimiento secuencial** (nuevas réplicas son añadidas de a una por vez) para obtener un estimador μ con un error relativo específico que sólo utiliza las réplicas que son realmente necesarias. El procedimiento asume que $X_1, X_2, \dots, X_n$ es una secuencia de variables aleatorias IID.

El objetivo específico del procedimiento es obtener un estimador de μ con un error relativo de γ ($0 < \gamma < 1$) y un nivel de confianza de $100(1-\alpha)\%$. Eligiendo un número inicial de réplicas con $n_0 \geq 2$ y sea:

$$\delta(n, \alpha) = t_{n-1, 1-\alpha/2} \sqrt{\frac{S^2(n)}{n}}$$

Es el intervalo de confianza de longitud media. Luego el procedimiento secuencial es como sigue:

0- Hacer n_0 réplicas de la simulación y setear $n = n_0$.

1- Calcular $\bar{X}(n)$ y $\delta(n, \alpha)$ desde $X_1, X_2, \dots, X_n$.

2- Si $\delta(n, \alpha)/|\bar{X}(n)| \leq \gamma'$, usar $\bar{X}(n)$ como el punto de estimación para μ y finalizar.

Equivalente,

$$I(\alpha, Y) = [\hat{X}(n) - \delta(n, \alpha); \hat{X}(n) + \delta(n, \alpha)]$$

Es aproximadamente un intervalo de confianza de $100(1-\alpha)\%$ para μ con la precisión deseada. Sino, reemplazar n por $n+1$ y hacer una réplica adicional de la simulación e ir al paso 1.

Notar que el procedimiento calcula un nuevo estimador de $\text{Var}(X)$ después de que se obtiene cada réplica, y el número total de réplicas requeridas por el procedimiento es una variable aleatoria.

9.4.3 Elección de condiciones iniciales:

Como vimos anteriormente las medidas de rendimiento para una simulación terminal depende explícitamente del estado del sistema a tiempo cero, entonces debemos tener cuidado cuando elegimos las condiciones iniciales. Ilustramos este problema con un ejemplo. Suponga que queremos estimar la demora promedio esperada de todos los clientes quienes arriban y completan su demora entre las 12pm del mediodía y la 1pm en el banco. Como el banco va a estar probablemente lleno al mediodía, empezar la simulación sin clientes presentes va a causar que nuestra estimación de la demora promedio sea parcialmente baja. Ahora se discuten 2 enfoques heurísticos para este problema, el primero se utiliza más ampliamente.

El primer enfoque, es el cual asumimos que el banco abre a las 9am sin clientes presentes. Entonces podemos correr la simulación por 4hs. Para estimar el tiempo de demora promedio, solo utilizaremos las demoras de los clientes que llegan y completan la espera entre el mediodía y la 1pm. La evolución de la simulación entre las 9am y el mediodía, determina las condiciones apropiadas para la simulación del mediodía. Una desventaja de este enfoque es que las 3hs de tiempo simulado, no son utilizadas para estimar. Como resultado, uno puede comenzar la simulación en algún otro horario, por ejemplo a las 11am. Sin embargo, no hay garantía de que las condiciones de la simulación de las 12pm serán representativas de las condiciones reales del banco a esa hora.

Un enfoque alternativo es recolectar datos de números de clientes presentes en el banco al mediodía en diferentes días. Tomamos p_i como la proporción de estos días en que están presentes i clientes ($i=1,2,\dots, n$) al mediodía. Luego simulamos el banco desde el mediodía hasta al 1pm con el número de clientes presentes al mediodía siendo seleccionados al azar desde la distribución de p_i .

9.7 Múltiples medidas de rendimiento:

En las secciones 9.4 y 9.6 se presentaron procedimientos para construir intervalos de confianza para una sola medida de rendimiento. Sin embargo para la mayoría de las simulaciones del mundo real varias medidas de rendimiento son requeridas simultáneamente.

Suponga que I_s es un intervalo de confianza con el $100(1-\alpha_s)\%$ de confianza para la medida de rendimiento μ_s (donde $s=1,2,\dots, K$). (Los μ_s pueden ser todas medidas de rendimiento para una simulación terminal o no terminal). Luego la probabilidad de que todos los K intervalos de confianza simultáneamente contengan sus respectivas verdaderas medidas satisface:

$$P(\mu_s \in I_s \forall s = 1, 2, \dots, k) \geq 1 - \sum_{s=1}^k \alpha_s$$

Donde las I_s pueden ser independientes o no. Este resultado es conocido como la **inecuación de Bonferroni**. Por ejemplo, suponer que se construyen intervalos de confianza con el 90% de confianza, esto es $\alpha_s=0,1$, para todas las s para 10 medidas de rendimiento distintas. Entonces, la probabilidad de que cada uno de los 10 intervalos de confianza contenga su verdadera medida de rendimiento solo puede afirmarse que es mayor o igual a cero. Entonces no se puede tener la totalidad de la confianza en cualquier conclusión sacada de este estudio. Esta dificultad se conoce en estadística como problema de múltiples comparaciones. Ahora describimos una solución práctica para el problema cuando K es pequeño. Si se quiere tener todo el

nivel de confianza asociado con K intervalos de confianza para que sea al menos $100(1-\alpha)$ porciento, elegir las α_s para que $\sum_{s=1}^K \alpha_s = \alpha$ (notar que los α_s no tienen que ser iguales. Entonces los α_s correspondientes a medidas más importantes pueden ser menores). Por lo tanto, uno puede construir 10 intervalos de confianza con el 99% de confianza y tener todo el nivel de confianza de al menos 90%. La dificultad con esta solución es que los intervalos de confianza serán más grandes que lo que eran originalmente, utilizando el procedimiento de la muestra de tamaño fijo, o se necesitan más datos para especificar los K errores, si se utiliza el procedimiento secuencial. Por esta razón, se recomienda que K no sea mayor de 10. Si se tiene un número muy grande de medidas de rendimiento, el único recurso disponible es construir los intervalos de confianza de 90% o 95% de confianza pero estando atento de que uno o más de estos intervalos probablemente no contenga la verdadera medida.

Capítulo 10

10.1 Introducción:

10.2 Métodos para determinar el intervalo de confianza para la diferencia de las medidas de rendimiento de 2 sistemas:

Acá consideramos un caso especial de comparación entre 2 sistemas sobre la base de alguna medida de rendimiento o respuesta esperada. Realizamos esta comparación formando un intervalo de confianza de la diferencia de las 2 expectativas, en lugar de hacer un test de hipótesis para ver si la diferencia observada es significativamente diferente de cero.

Para $i=1,2$, tomamos $X_{i1}, X_{i2}, \dots, X_{in_i}$ como una muestra de n_i IID observaciones para el sistema i y sea $\mu_i = E(X_{ij})$ la respuesta esperada de interés; queremos construir un intervalo de confianza para $\xi = \mu_1 - \mu_2$. El hecho de que X_{1j} y X_{2j} sean independientes depende de cómo se ejecuten las simulaciones y esto determina cual de los 2 enfoques de intervalos de confianza se utilizará.

10.2.1 Intervalo de confianza t-apareado:

Si $n_1 = n_2 = n$, o estamos dispuestos a descartar algunas observaciones del sistemas, podemos emparejar X_{1j} con X_{2j} para definir $Z_j = X_{1j} - X_{2j}$ para $j=1,2,\dots, n$. Luego las Z_j son variables aleatorias IID y $E(Z_j) = \xi$, la cantidad para la cual queremos construir el intervalo de confianza. Entonces podemos tomar:

$$\bar{Z}(n) = \frac{\sum_{j=1}^n Z_j}{n}$$

$$\widehat{Var}[\bar{Z}(n)] = \frac{\sum_{j=1}^n [Z_j - \bar{Z}(n)]^2}{n(n-1)}$$

Y el intervalo de confianza de $100(1-\alpha)\%$ de confianza es:

$$\bar{Z}(n) \pm t_{n-1, 1-\alpha/2} \sqrt{\widehat{Var}[\bar{Z}(n)]}$$

Un punto importante a destacar es que no fue necesario asumir que X_{1j} y X_{2j} son independientes ni tampoco fue necesario asumir que $\text{Var}(X_{1j}) = \text{Var}(X_{2j})$.

10.2.2 Intervalo de confianza Welch:

Un segundo enfoque para formar un intervalo de confianza para ξ no empareja las observaciones de los 2 sistemas, pero requiere que las X_{1j} sean independientes de las X_{2j} . Sin embargo n_1 y n_2 pueden ser diferentes para aplicar el clásico enfoque two-sample-t debemos asegurar que $\text{Var}(X_{1j}) = \text{Var}(X_{2j})$, si estas varianzas no son iguales, el intervalo de confianza two-sample-t sufre una degradación. Sin embargo, si $n_1 = n_2$, el enfoque two-sample-t es bastante seguro incluso si las varianzas difieren. Ya que la igualdad de varianzas es una suposición poco segura, no se recomienda usar el enfoque two-sample-t.

En lugar de este, se recomienda usar los problemas de varianzas distintas cuando las X_{ij} son distribuidas normalmente la solución obtenida por Welch es:

$$\bar{X}_i(n_i) = \frac{\sum_{j=1}^{n_i} X_{ij}}{n_i}$$

$$S_i^2(n_i) = \frac{\sum_{j=1}^{n_i} [X_{ij} - \bar{X}_i(n_i)]^2}{n_i - 1}$$

Para $i=1,2$. Luego,

$$\bar{X}_1(n_1) - \bar{X}_2(n_2) \pm t_{\hat{f}, 1-\alpha/2} \sqrt{\frac{S_1^2(n_1)}{n_1} + \frac{S_2^2(n_2)}{n_2}}$$

Siendo $\hat{f} = g(s_1, s_2, n_1, n_2)$.

Este es el intervalo de confianza con aproximadamente $100(1-\alpha)\%$ de confianza para ξ . Como $\hat{f}$ en general no es un entero, se necesitara la interpolación en las tablas t. El intervalo de confianza anterior, el cual llamamos intervalo de confianza de Welch, puede ser utilizado para validar un modelo de simulación para un sistema real. Si el sistema 1 es un sistema del mundo real para el cual tenemos datos físicamente recolectados y el sistema 2 que se corresponde con un modelo de simulación para el cual se tiene datos de la salida de la simulación, es muy probable que n_1 sea mucho menor que n_2 .

Características:

- n_1 puede ser distinto de n_2 .
- Es indispensable asegurar independencia de las réplicas.
- No es necesario que las variables sean iguales.

10.3 Intervalos de confianza para comparar más de 2 sistemas:

Si solo tenemos que comparar 2 sistemas, los métodos en la sección 10.2 proveen una forma de construir los intervalos de confianza para la diferencia entre medidas de rendimiento. Sin embargo, en algunos estudios hay más de 2 sistemas, pero todavía podemos utilizar un enfoque de intervalo de confianza. Haremos varias declaraciones de intervalos de confianza, entonces cada uno de sus niveles de confianza individual, debe superar el nivel de confianza total.

Utilizaremos la inecuación de Bonferroni para asegurarnos que el nivel de confianza total sea al menos de $1-\alpha$. Recordando, la inecuación de Bonferroni implica que si queremos realizar c intervalos de confianza, entonces haremos cada intervalo de confianza individual con un nivel de confianza de $1-\alpha/c$, así el nivel de

confianza total será de al menos $1-\alpha$. Por ejemplo, si queremos construir $c=10$ intervalos y tener un nivel de confianza total de $100(1-\alpha)\%=90$ debemos hacer cada intervalo individual con un nivel de confianza del 99%.

10.4 Selección y Ranking:

10.4.1 Seleccionar el mejor de K sistemas:

Tomamos X_{ij} como la variable aleatoria de interés (medida de rendimiento) de la j -ésima réplica del i -ésimo sistema y sea $\mu_i = E(X_{ij})$. Para esta selección, así como también para las de las selecciones siguientes, los X_{ij} se asumen independientes entre sí.

Tomamos $\mu_{(l)}$ como el l -ésimo menor de todos los μ_i de tal forma que $\mu_{(1)} \leq \mu_{(2)} \leq \dots \leq \mu_{(K)}$. Nuestro objetivo en esta sección es seleccionar el sistema con la menor respuesta esperada, $\mu_{(l)}$ (si quisiéramos el mayor promedio $\mu_{(K)}$, los signos de los X_{ij} y los μ_i pueden ser revertidos).

Tomamos a CS como el evento de selección correcta.

La aleatoriedad inherente de los X_{ij} implica que nunca estaremos totalmente seguros de que haremos la CS, pero estamos en condiciones de pre-especificar la probabilidad de CS. Además, si $\mu_{(1)}$ y $\mu_{(2)}$ son muy cercanos, podríamos no preocuparnos si elegimos incorrectamente el sistema i_2 (el que tiene promedio $\mu_{(2)}$), entonces queremos un método que evite realizar un gran número de réplicas para resolver esta diferencia insignificante, la formulación exacta del problema es que queremos que $P(CS) \geq P^*$ previniendo que $\mu_{(2)} + \mu_{(1)} \geq d^*$, donde la probabilidad mínima aceptada $P^* > \frac{1}{K}$ y la cantidad de indiferencia $d^* > 0$ ambos especificados por el analista. Es natural preguntar qué pasa si la probabilidad es de al menos P^* , la respuesta esperada del sistema no será mayor que $\mu_{(1)} + d^*$.

El procedimiento estadístico para resolver este problema involucra dos etapas de muestreo de cada uno de los K sistemas, en la primera etapa hacemos un número fijo de réplicas de cada sistema, y luego utilizando las estimaciones de la varianza obtenidas determinamos cuantas réplicas más son necesarias para cada sistema, en la segunda etapa de muestreo. Debe asumirse que las X_{ij} son normalmente distribuidas pero no es necesario asumir que $\sigma^2_{i1} = \text{Var}(X_{ij})$ ni tampoco que σ^2 son las mismas para los diferentes i .

En la primera etapa, hacemos $n_0 \geq 2$ réplicas de cada uno de los K sistemas y definimos las medias y varianzas de la primera etapa.

$$\bar{X}_i^{(1)}(n_0) = \frac{\sum_{j=1}^{n_0} X_{ij}}{n_0}$$

$$S_i^2(n_0) = \frac{\sum_{j=1}^{n_0} [X_{ij} - \bar{X}_i^{(1)}(n_0)]^2}{n_0 - 1}$$

Para $i=1,2,\dots,K$. Luego calculamos el total de muestras N_i necesarias para el sistema i :

$$N_i = \max \left\{ n_0 + 1, \left\lceil \frac{h_1^2 S_i^2(n_0)}{(d^*)^2} \right\rceil \right\} \quad (1)$$

Donde $[X]$ es el entero más chico el cual es mayor o igual al verdadero número X y h_1 (la cual depende de K , P^* y n_0) es una constante que se obtiene de una tabla. Luego, hacemos $N_i - n_0$ réplicas más del sistema i ($i=1,2,\dots,K$) y obtenemos las medias de la segunda etapa de muestreo.

$$\bar{X}_i^{(2)}(N_i - n_0) = \frac{\sum_{j=n_0+1}^{N_i} X_{ij}}{N_i - n_0}$$

Finalmente

$$\bar{X}_i(N_i) = \left(W_{i1} * \bar{X}_i^{(1)}(n_0) \right) + \left(W_{i2} * \bar{X}_i^{(2)}(N_i - n_0) \right)$$

Y seleccionamos el sistema con menor $\bar{X}_i(N_i)$.

Las elecciones de P^* y d^* dependen de los objetivos del analista y el sistema bajo estudio. Sin embargo elegir el n_0 es más complicado y en base a experiencia y algunas literaturas se sabe que n_0 tiene que ser al menos 20. Si n_0 es muy chico, se obtienen estimaciones pobres de $S_i^2(n_0)$. Por otra parte, si n_0 es muy grande, podemos hacer demasiadas réplicas innecesarias para algunos sistemas.

10.4.2 Seleccionar un subconjunto de tamaño m que contiene al menor de K sistemas.

Ahora consideraremos un problema de selección distinto, que es seleccionar un subconjunto de exactamente m de K sistemas con probabilidad de al menos P^* . El subconjunto seleccionado contendrá el sistema con la respuesta media más pequeña μ_{i1} . Esto podría ser un objetivo en las etapas iniciales de una simulación, donde podría haber un número grande K de sistemas alternativos y podríamos querer eliminar aquellos que claramente son inferiores.

Definimos X_{ij} , μ_i , μ_{ij} y σ_i^2 como en la sección 10.4.1. Otra vez, todas las X_{ij} son independientes y normales, y para un valor fijo i, $X_{i1}, X_{i2}, \dots, X_{ik}$ son IID; las σ_i^2 son desconocidas y no necesitan ser iguales. Acá, la correcta selección (CS) es que el subconjunto de tamaño m que fue seleccionado contenga el sistema con media μ_{i1} y queremos que $P(\text{CS}) \geq P^*$ previendo que $\mu_{i2} - \mu_{i1} \geq d^*$. Acá debemos tener que $1 \leq m \leq K-1$, $P^* > m/k$ y $d^* > 0$. (Si $\mu_{i2} - \mu_{i1} < d^*$ con probabilidad de al menos P^* , el subconjunto contendrá al sistema con una respuesta esperada que no es más grande que $\mu_{i2} + d^*$).

El procedimiento es muy similar al de la sección 10.4.1. En una primera etapa tomamos una muestra de $n_0 \geq 2$ réplicas de cada sistema y definimos $\bar{X}_i^{(1)}(n_0)$ y $S_i^2(n_0)$ para $i=1, 2, \dots, K$, exactamente como en la sección 10.4.1. Luego calculamos el número total de réplicas, N_i , necesitadas para el i-ésimo sistema (Ecuación 1), excepto que h_1 es reemplazado por h_2 (lo cual depende de m, K, P^* y n_0) que se encuentra en una tabla. Luego hacemos $N_i - n_0$ réplicas mas para la segunda etapa. Definimos $\bar{X}_i^{(2)}(N_i - n_0)$, los pesos W_{i1} y W_{i2} y obtenemos $\bar{X}_i(N_i)$, exactamente como en la sección 10.4.1. Finalmente, seleccionamos el subconjunto de m sistemas con los m menores valores de $\bar{X}_i(N_i)$.

10.4.3 Seleccionar los m mejores de K sistemas:

Consideraremos como objetivo seleccionar un subconjunto de un tamaño especificado m ($1 \leq m \leq K-1$) con probabilidad de al menos P^* , de tal forma que las respuestas esperadas del subconjunto seleccionado sean las m respuestas con menor μ ($\mu_{i1}, \mu_{i2}, \dots, \mu_{im}$). Es importante notar que los m sistemas con las respuestas esperadas más chicas están desordenados. Esta selección puede ser útil si queremos identificar varias opciones buenas, ya que el sistema puede ser inaceptable por otras razones, por ejemplo políticas o ambientales.

La situación (independencia, normalidad, varianzas distintas y desconocidas, etc.) es la misma que en la sección 10.4.2 excepto que la constante P^* puede ser cambiada. Queremos que $P(\text{CS}) \geq P^*$ previendo que $\mu_{i(m+1)} - \mu_{im} \geq d^*$. CS se redefine como que las respuestas del subconjunto seleccionado son iguales a aquellas de los m sistemas mejores.

(Si la condición de que $\mu_{im+1} - \mu_{im} \Rightarrow d^*$ falla, con probabilidad de al menos P^* , las respuestas esperadas de los m sistemas seleccionados no excederá $\mu_{im} + d^*$). También, debemos tener que $P^* > m!(K-m)!/K!$. El procedimiento para la solución es exactamente el mismo que el procedimiento para la solución de la sección 10.4.2, excepto que la constante h_2 se reemplaza por h_3 , que se puede encontrar en una tabla.